



Escuela
Politécnica
Superior

Detección de estrés a partir de señales fisiológicas multimodales mediante aprendizaje automático



Grado en Ingeniería en Sonido e
Imagen en Telecomunicación

Trabajo Fin de Grado

Autora:

Raquel Gomez

Tutores:

Encarnación Gimeno Nieves

Roberto Fernández Fernández

Julio 2026



Universitat d'Alacant
Universidad de Alicante

Agradecimientos

En primer lugar, quiero agradecer a mis tutores, sin quienes este trabajo no habría sido posible. A Encarna Gimeno Nieves, por su amplia disponibilidad en todo momento, por no cerrarme nunca una puerta y por la alegría con la que afronta su trabajo. Y a Roberto Fernández Fernández, por su exigencia y, precisamente por ello, por animarme a no conformarme con lo suficiente y hacerme confiar en mi misma.

A mis amigas, Sofía y Marianela, por acompañarme en todo el recorrido de la carrera. Gracias por los apuntes compartidos, por las comidas en el club social, por los nervios antes de cada examen y sobre todo por las risas. Hicisteis que los días difíciles pesaran menos y que los buenos se disfrutaran el doble.

Por último, y de todo corazón, a mi familia. A mis padres, por haberme animado y motivado desde el minuto uno, por creer en mí incluso antes de que yo lo hiciera y por sostenerme, con paciencia y cariño, en cada caída y cada logro. A mi hermana Camila, por ser mi motivación y por enseñarme lo que es una ingeniería, demostrándome con su ejemplo que sí se puede, que el esfuerzo merece la pena y que no hay meta demasiado grande cuando se persigue con constancia. Y muy especialmente a mi hermana Lucía, por ser al mismo tiempo mi apoyo más cercano, mi compañera de vida y mi amiga, gracias por caminar a mi lado en cada etapa, por escucharme siempre y por recordarme quién soy y hasta dónde puedo llegar.

A todos vosotros, de corazón, gracias.

*“Our fate lives within us.
You only have to be brave
enough to see it.”*

Merida, Brave

Índice general

1. Introducción	1
1.1. Motivación científica y tecnológica	1
1.2. Contexto técnico del problema	1
1.3. Marco del proyecto	1
2. Marco Teórico	3
2.1. Introducción	3
2.2. Estudios previos y trabajos relacionados	3
2.3. Electrocardiograma (ECG)	4
2.4. Actividad Electrodermica (EDA)	5
2.5. Electromiograma (EMG)	5
2.6. Fotopletismografía (PPG) y Volumen de Pulso Sanguíneo (BVP)	6
2.7. Frecuencia Cardíaca (HR) e Intervalos RR	7
2.8. Respiración (RESP)	8
2.9. Temperatura Cutánea y Temperatura Periférica (SKT/TEMP)	8
2.10. Biopac	9
2.11. Empatica E4	10
2.12. De la evaluación subjetiva del estrés a los biomarcadores fisiológicos	11
2.13. Aprendizaje automático: conceptos básicos	11
2.14. Random Forest (RF)	12
2.15. Light Gradient Boosting Machine (LightGBM)	13
2.16. Support Vector Machine (SVM)	14
2.17. K-Nearest Neighbors (KNN)	15
3. Objetivos	17
3.1. Objetivo general	17
3.2. Objetivos específicos	17
4. Metodología	19
4.1. Base de datos: <i>A Multimodal Dataset for Investigating Working Memory in Presence of Music</i>	19
4.1.1. Protocolo experimental	19
4.1.2. Señales registradas	20
4.1.3. Estructura y acceso a los datos	21
4.2. Entorno de desarrollo	21
4.3. Preprocesamiento de señales	22
4.3.1. Carga de datos	22
4.3.2. Eliminación de artefactos	23
4.3.3. Segmentación por sesión	23
4.4. Diseño del sistema de detección de estrés	23
4.4.1. Normalización de los datos	24
4.4.2. Segmentación en ventanas deslizantes	25
4.4.3. Extracción de características	26
4.4.4. Etiquetado fisiológico por votación ponderada	26

4.4.5.	Clasificadores empleados	27
4.4.6.	Evaluación del rendimiento (Diagrama de bloques, curvas Receiver Operating Characteristic (ROC), Área Bajo la Curva (AUC) y validación cruzada	28
4.5.	Diseño de la aplicación	28
4.5.1.	Pantalla de configuración inicial	29
4.5.2.	Panel lateral y gestión de sujetos	29
4.5.3.	Módulo de visualización	30
4.5.4.	Módulo de análisis	30
5.	Desarrollo	33
5.1.	Exploración inicial de los datos	33
5.1.1.	Inspección y verificación de archivos	33
5.1.2.	Conversión de formatos	33
5.1.3.	Reajuste de bases de datos.	34
5.2.	Representación de señales	35
5.2.1.	Representación inicial de señales	35
5.2.2.	Segmentación por sesión experimental	35
5.3.	Desarrollo de la interfaz gráfica	37
5.3.1.	Arquitectura y organización del código	37
5.3.2.	Ventana de configuración inicial	39
5.3.3.	Ventana principal	40
5.3.4.	Carga automática de sujetos	42
5.3.5.	Representación de las señales fisiológicas	42
5.3.6.	Representación de las fases experimentales	43
5.3.7.	Herramientas de navegación	44
5.3.8.	Panel de análisis	44
5.3.9.	Exportación de resultados	49
5.3.9.1.	Validación Leave-One-Subject-Out (LOSO)	50
5.3.10.	Disponibilidad del código fuente y documentación	51
6.	Resultados	53
6.1.	Conjuntos de datos y configuración del análisis	53
6.2.	Validación de la representación de las señales	53
6.2.1.	Base de datos 1: señales Biopac	54
6.2.2.	Base de datos 2: señales Empatica	55
6.3.	Resultados de detección de estrés con Biopac (Base de datos 1)	57
6.3.1.	Análisis detallado de un sujeto representativo	58
6.3.2.	Resultados globales de sujeto demostrativo de Biopac	60
6.3.3.	Resultados globales de la Base de datos 1 completa	62
6.4.	Resultados de detección de estrés con Empatica (Base de datos 2)	63
6.4.1.	Análisis en detalle del sujeto descriptivo de la Base de datos 2	63
6.4.2.	Resultados globales de la Base de datos 2 completa	63
6.5.	Comparación entre dispositivos y discusión	66
6.5.1.	Validación LOSO	67
7.	Conclusiones y líneas futuras	69
	Bibliografía	71
	Lista de Acrónimos y Abreviaturas	75

A. Anexo I: Manual de BioVisor

77

Índice de figuras

2.1.	Ciclo cardíaco representado en una señal de ECG, con la onda P, el complejo QRS, la onda T y la onda U marcadas. Fuente: [11].	4
2.2.	Señal de EDA descompuesta en su parte tónica (SCL) y su parte fásica (SCR). Fuente: [12].	5
2.3.	Señal de EMG en reposo frente a la señal registrada durante una contracción muscular. Fuente: [15].	6
2.4.	Forma de onda de una señal PPG/BVP, con el pico sistólico, la escotadura diastólica y el pico diastólico marcados. Fuente: [17].	6
2.5.	Variabilidad del ritmo cardíaco a lo largo de una serie de latidos consecutivos. Fuente: [18].	7
2.6.	Ciclo respiratorio, mostrando las fases de inspiración y espiración junto al volumen pulmonar asociado. Fuente: [22].	8
2.7.	Evolución de la temperatura periférica a lo largo del día. Fuente: [24].	9
2.8.	Unidad de adquisición de datos BIOPAC MP35 empleada en el estudio.	9
2.9.	Sensores y accesorios del sistema BIOPAC, incluyendo el cableado, los electrodos y el cinturón respiratorio.	10
2.10.	Pulsera Empatica E4 utilizada para la adquisición de señales fisiológicas.	11
2.11.	Funcionamiento de Random Forest: una muestra nueva pasa por varios árboles de decisión independientes y la predicción final se decide por votación mayoritaria o promediado. Fuente: [31].	13
2.12.	Crecimiento hoja a hoja en LightGBM: en cada paso se expande la hoja que produce mayor reducción de la pérdida. Fuente: [32].	14
2.13.	Funcionamiento de una SVM: hiperplano de separación óptimo, margen máximo y vectores de soporte de cada clase. Fuente: [33].	15
2.14.	Funcionamiento de KNN con $k = 3$: el nuevo punto se clasifica según la clase mayoritaria entre sus tres vecinos más cercanos. Fuente: [34].	16
4.1.	Representación de tareas cognitivas n-back . Fuente: [35]	19
4.2.	Disposición de los dispositivos utilizados para la adquisición de señales fisiológicas en el estudio correspondiente a la base de datos principal empleada en este Trabajo de Fin de Grado. Fuente: [35].	20
4.3.	<i>Pipeline</i> completo de detección de estrés implementado en BioVisor. Cada bloque corresponde a una etapa del proceso, desde la carga de las señales fisiológicas hasta la estimación de la probabilidad de estrés a lo largo del tiempo.	24
4.4.	Esquema visual de la interfaz de BioVisor.	29
5.1.	Representación conjunta con código inicial del Sujeto 1 de la Base de datos 1. . .	36
5.2.	Arquitectura de la aplicación en dos capas: núcleo (lógica de procesamiento) e interfaz (ventanas de usuario).	38
5.3.	Estructura modular del proyecto BioVisor.	38
5.4.	Proceso de configuración inicial de BioVisor. (a) Ventana emergente inicial mostrada al ejecutar la aplicación. (b) Selección de la carpeta que contiene la base de datos mediante el asistente de configuración.	39

5.5.	Carga de un sujeto en la aplicación BioVisor. (a) Representación inicial de las señales fisiológicas correspondientes al sujeto seleccionado. (b) Visualización de las señales tras la detección de artefactos durante el proceso de análisis.	41
5.6.	Representación de señales base en la aplicación BioVisor.	43
5.7.	Ejemplos de zoom sobre señales fisiológicas en BioVisor. (a) Ampliación mediante la herramienta de zoom sobre la fase de música relajante, permitiendo observar con mayor detalle la evolución de las señales. (b) Visualización del límite temporal entre el periodo de relajación y el inicio de la fase de música estresante, donde puede apreciarse el cambio de condición experimental.	44
5.8.	Ventana de configuración del análisis en BioVisor, desde la que el usuario puede seleccionar el modelo de aprendizaje automático, las señales fisiológicas que se emplearán durante el análisis y los parámetros necesarios para ejecutar la estimación del nivel de estrés.	45
5.9.	Proceso de exportación de la probabilidad de estrés en formato CSV. (a) Selección del archivo CSV que se desea exportar desde la aplicación. (b) Mensaje mostrado tras completar la exportación del archivo. (c) Contenido del archivo CSV generado con los valores de probabilidad de estrés obtenidos durante el análisis.	50
6.1.	Representación de las señales fisiológicas originales correspondientes a los cinco sujetos de la Base de Datos 1 para el dispositivo Biopac	55
6.2.	Comparación entre las señales del sujeto 9 publicadas en el artículo de referencia de la Base de Datos 2 y las representadas en BioVisor.	55
6.3.	Representación en BioVisor de las señales fisiológicas registradas mediante los dispositivos Empatica para el resto de sujetos de la Base de Datos 2.	57
6.4.	Resultados del modelo Random Forest sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.	58
6.5.	Resultados del modelo LightGBM sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.	58
6.6.	Resultados del modelo SVM sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.	59
6.7.	Resultados del modelo KNN sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.	59
6.8.	Gráficas generales del sujeto 1 de la Base de datos 1: (a) intervalo RR obtenido a partir de la señal de ECG; (b) frecuencia respiratoria obtenida a partir de la señal de respiración.	60
6.9.	Resultados globales del modelo Random Forest para el sujeto 1 de la Base de datos 1: (a) probabilidad de estrés combinada de todas las señales; (b) mapa de calor de la envolvente de la probabilidad media de estrés.	61
6.10.	Resultados globales del modelo LightGBM para el sujeto 1 de la Base de datos 1: (a) probabilidad de estrés combinada de todas las señales; (b) mapa de calor de la envolvente de la probabilidad media de estrés.	61
6.11.	Resultados globales del modelo SVM para el sujeto 1 de la Base de datos 1: (a) probabilidad de estrés combinada de todas las señales; (b) mapa de calor de la envolvente de la probabilidad media de estrés.	61
6.12.	Resultados globales del modelo KNN para el sujeto 1 de la Base de datos 1: (a) probabilidad de estrés combinada de todas las señales; (b) mapa de calor de la envolvente de la probabilidad media de estrés.	62

6.13.	Resultados de la probabilidad de estrés obtenida con el modelo global entrenado sobre la Base de datos 1. (a) Probabilidad de estrés para el sujeto 2. (b) Probabilidad de estrés para el sujeto 3. (c) Probabilidad de estrés para el sujeto 4. (d) Probabilidad de estrés para el sujeto 5.	62
6.14.	Probabilidad de estrés estimada mediante el modelo global de Random Forest para los sujetos 1 a 4 de la Base de datos 2. (a) Sujeto 1. (b) Sujeto 2. (c) Sujeto 3. (d) Sujeto 4.	64
6.15.	Probabilidad de estrés estimada mediante el modelo global de Random Forest para los sujetos 5 a 8 de la Base de datos 2. (a) Sujeto 5. (b) Sujeto 6. (c) Sujeto 7. (d) Sujeto 8.	65
6.16.	Probabilidad de estrés estimada mediante el modelo global de Random Forest para los sujetos 9 y 10 de la Base de datos 2. (a) Sujeto 9. (b) Sujeto 10.	65

Índice de tablas

4.1.	Señales fisiológicas registradas en el dataset y dispositivos empleados.	20
4.2.	Principales librerías de Python empleadas en el desarrollo de BioVisor	21
5.1.	Tiempos de inicio y fin de las fases de música relajante y música estresante obtenidos a partir de los archivos Triggers_block.csv de la Base de Datos 1.	37
6.1.	Resumen de las dos bases de datos empleadas.	54
6.2.	AUC obtenido por cada modelo y señal para el sujeto representativo de la Base de datos 1.	59
6.3.	AUC obtenido por cada modelo y señal para el sujeto representativo de la Base de datos 2.	63
6.4.	Comparación general entre los dispositivos Biopac y Empatica.	66
6.5.	Resultados de la validación Leave-One-Subject-Out (modelo multimodal fusionado) para la Base de datos 1 (Biopac).	67
6.6.	Resultados de la validación Leave-One-Subject-Out (modelo multimodal fusionado) para la Base de datos 2 (Empatica).	68

Índice de Códigos

5.1. Presets de dispositivo definidos en <code>config.py</code>	39
5.2. Aplicacion del filtrado a todas las senales (<code>filters.py</code>)	41
5.3. Colores de fase y calculo del periodo de relajacion	43
5.4. Construccion de los clasificadores disponibles	45
5.5. Vector de características por ventana (fragmento de <code>_window_features</code>)	46
5.6. Filtro de Butterworth paso banda empleado en la deteccion de picos	46
5.7. Extraccion de la frecuencia respiratoria a partir de los cruces por cero (rama RESP de <code>_window_features</code>)	47
5.8. Tuberia de clasificacion y evaluacion por validacion cruzada	48

1. Introducción

1.1. Motivación científica y tecnológica

En los últimos años, el análisis de señales biomédicas ha despertado un gran interés, principalmente por el avance de la tecnología y la aparición de sensores capaces de registrar información fisiológica de forma sencilla y cada vez más precisa. Gracias a ello, hoy en día es posible obtener datos sobre el funcionamiento del cuerpo de manera continua y utilizarlos para estudiar cómo responde una persona ante diferentes situaciones.

Una de las aplicaciones más interesantes es el estudio de la influencia que tienen distintos estímulos, como la música, sobre el sujeto. Dependiendo del tipo de música o de las características de cada persona, pueden producirse cambios en señales fisiológicas como la frecuencia cardíaca, la actividad electrodérmica o la temperatura de la piel. Analizar estos cambios permite comprender mejor cómo reacciona el cuerpo y facilita el desarrollo de herramientas capaces de detectar e interpretar estas respuestas de forma automática, lo que puede resultar de gran utilidad en aplicaciones relacionadas con la salud y el bienestar.

1.2. Contexto técnico del problema

Existen diferentes señales fisiológicas que permiten conocer cómo está respondiendo el organismo en cada momento. Entre las más utilizadas se encuentran el Electrocardiograma (ECG), la Actividad Electrodérmica (EDA), la Fotopletismografía (PPG) y el Intervalo entre Latidos (RR). Cada una aporta información distinta sobre el funcionamiento del cuerpo y, al analizarlas de manera conjunta, es posible obtener una visión más completa del estado fisiológico de una persona.

No obstante, el análisis conjunto de varias señales fisiológicas sigue presentando ciertas dificultades. Es posible representar cada señal mediante código propio o utilizando funciones específicas disponibles en distintos entornos de programación, lo que facilita el estudio individual de cada una de ellas. Sin embargo, no existen aplicaciones que integren de forma sencilla y gratuita todas las señales fisiológicas de un mismo sujeto en un único entorno de análisis, especialmente cuando se trata de estudios centrados en la relación entre la música y el estrés. Esta ausencia de herramientas obliga, en muchos casos, a procesar y visualizar las señales por separado, dificultando el análisis conjunto y la interpretación global de los resultados.

1.3. Marco del proyecto

Este Trabajo Final de Grado (TFG) tiene como objetivo el desarrollo de una aplicación de código abierto que facilite la visualización y el análisis conjunto de diferentes señales fisiológicas registradas durante un experimento. La herramienta ha sido diseñada para servir de apoyo en el análisis y la

visualización de señales fisiológicas, permitiendo estudiar la respuesta del organismo ante distintos estímulos y condiciones experimentales en diversos contextos de investigación biomédica.

Para llevar a cabo este TFG se han utilizado los conjuntos de datos públicos *A Multimodal Dataset for Investigating Working Memory in Presence of Music* [1] y *Regulation of Brain Cognitive States through Auditory, Gustatory, and Olfactory Stimulation with Wearable Monitoring* [2], disponibles en **PhysioNet** [3]. Estos conjuntos de datos recogen diferentes señales fisiológicas registradas a varios participantes mientras realizaban **pruebas de memoria de trabajo en presencia de distintos tipos de música**, proporcionando un entorno adecuado para analizar cómo varía la respuesta del organismo durante el experimento.

La aplicación desarrollada permite visualizar de forma sincronizada las distintas señales de un mismo sujeto, facilitando su **exploración y el análisis de los cambios fisiológicos** que se producen a lo largo de las diferentes fases del experimento. Además de la representación gráfica de las señales, se han incorporado **herramientas de procesamiento y análisis basadas en técnicas de aprendizaje automático**, permitiendo evaluar la **capacidad de distintos modelos para detectar situaciones de estrés** a partir de la información fisiológica registrada.

El resultado es una **aplicación de código abierto que permite estudiar de forma sencilla y reproducible la relación entre la música, la memoria de trabajo y la respuesta fisiológica de las personas participantes**. Al tratarse de una herramienta libre y modular, cualquier grupo de investigación puede utilizarla y extenderla sin coste, lo que abre la puerta a la estandarización de los flujos de análisis de señales fisiológicas y a un intercambio de resultados más ágil y transparente entre laboratorios.

A lo largo de este TFG se abordará, en primer lugar, la teoría relevante para la correcta comprensión del trabajo. A continuación, se expondrán la metodología y el desarrollo de la aplicación, que constituye el principal objetivo del proyecto. Finalmente, se presentarán los resultados obtenidos al ejecutar las distintas bases de datos en la aplicación desarrollada, **BioVisor**.

2. Marco Teórico

2.1. Introducción

Antes de describir el desarrollo del trabajo, es necesario presentar algunos conceptos que servirán de base para comprender el resto de la memoria. A lo largo del proyecto se combinan conocimientos relacionados con la **fisiología humana**, la **recopilación y procesamiento de señales biomédicas** y el **aprendizaje automático**, por lo que resulta conveniente introducir brevemente estos aspectos.

En este capítulo se describen las **principales señales fisiológicas** empleadas en el estudio, explicando qué información proporciona cada una de ellas y cómo se obtienen. Asimismo, se presentan los **conceptos básicos del procesamiento de señales** y de los **modelos de aprendizaje automático** utilizados posteriormente para la detección del estrés. De esta forma, se pretende facilitar la comprensión de la metodología seguida y justificar las decisiones adoptadas durante el desarrollo del proyecto.

2.2. Estudios previos y trabajos relacionados

Antes de profundizar en las señales fisiológicas y en los algoritmos empleados, resulta necesario contextualizar este trabajo dentro de la investigación existente. En los últimos años se han publicado numerosos estudios centrados en la detección del estrés y de la carga cognitiva a partir de señales fisiológicas, utilizando tanto equipos de laboratorio como dispositivos portátiles (**wearables**).

Actualmente, PhysioNet [3] dispone de 32 bases de datos correspondientes a estudios multimodales. De ellas, únicamente tres están centradas en tareas cognitivas para entrenar la memoria de trabajo de tipo **n-back**: **Mental Workload during n-back Task Captured by Transcranial Doppler (TCD) Sonography and Functional Near-Infrared Spectroscopy (fNIRS) Monitoring** [4], **Regulation of Brain Cognitive States through Auditory, Gustatory, and Olfactory Stimulation with Wearable Monitoring** [5] y **A Multimodal Dataset for Investigating Working Memory in Presence of Music** [6]. Estas dos últimas constituyen las principales fuentes de datos utilizadas en este TFG.

Asimismo, dentro de PhysioNet se encuentran 13 artículos con el estrés como fuente principal de estudio y diversos estudios que emplean el mismo dispositivo electrónico, la pulsera Empatica, para la adquisición de señales fisiológicas. Entre ellos destacan **CogWear: Can We Detect Cognitive Effort with Consumer-Grade Wearables?** [7], **BIG IDEAs Lab Glycemic Variability and Wearable Device Data** [8], **Wearable Device Dataset from Induced Stress and Structured Exercise Sessions** [9] y **ScientISST MOVE: Annotated Wearable Multimodal Biosignals Recorded During Everyday Life Activities in Naturalistic Environments** [5]. Estos trabajos ponen de manifiesto el creciente interés por el uso de dispositivos **wearables** para el registro de señales fisiológicas en distintos escenarios de estudio.

Por otro lado, en PhysioNet existen más de 55 trabajos que incorporan técnicas de aprendizaje automático (**machine learning**) para el análisis de señales biomédicas. Esto demuestra que este tipo de metodologías se ha consolidado como una herramienta eficaz para el **procesamiento y la clasificación de datos fisiológicos**. Por este motivo, en este trabajo también se plantea el desarrollo de un **modelo basado en aprendizaje automático** para la estimación del nivel de estrés.

La base de datos utilizada como referencia principal es **A Multimodal Dataset for Investigating Working Memory in Presence of Music** [6]. A partir de ella se han tomado como referencia las señales fisiológicas analizadas, los dispositivos empleados durante la adquisición de datos y las frecuencias de muestreo correspondientes. Además, también se ha utilizado el conjunto de datos **Regulation of Brain Cognitive States through Auditory, Gustatory, and Olfactory Stimulation with Wearable Monitoring** [5], con el fin de contrastar la metodología empleada y comprobar que el procedimiento desarrollado es aplicable a otros estudios con una estructura de datos similar.

2.3. Electrocardiograma (ECG)

El ECG es una prueba que registra de forma no invasiva la **actividad eléctrica que genera el corazón** en cada latido, captándola mediante electrodos colocados sobre la piel. Cada latido queda representado por una serie de ondas que se identifican con las letras P, Q, R, S, T y U, y que corresponden a las distintas fases de despolarización y repolarización tanto de las aurículas como de los ventrículos [10].

En la Figura 2.1 se muestra un ciclo cardíaco completo, donde puede verse una **sucesión de ondas bien diferenciadas** cuya forma y duración sirven como indicadores de cómo está funcionando el corazón en ese momento.




Figura 2.1 Ciclo cardíaco representado en una señal de ECG, con la onda P, el complejo QRS, la onda T y la onda U marcadas. Fuente: [11].

2.4. Actividad Electrodérmica (EDA)

La EDA mide los cambios que se producen en la **conductancia eléctrica de la piel** debido a la actividad de las **glándulas sudoríparas ecrinas**, que a su vez están controladas por el sistema nervioso autónomo simpático. Dentro de esta señal se distinguen dos partes: el Nivel de Conductancia de la Piel (SCL), que cambia de forma lenta y tónica, y la Respuesta de Conductancia de la Piel (SCR), que aparece de forma más rápida cuando el cuerpo reacciona ante un estímulo concreto [12]. Esta señal es uno de los indicadores más utilizados a la hora de detectar estrés.

Se aprecia en la Figura 2.2 cómo, por un lado, hay una componente de fondo que varía despacio y marca el **nivel general de activación**, y por otro aparecen picos puntuales que corresponden a **reacciones concretas del sujeto ante algo que ha pasado** en ese instante.




Figura 2.2 Señal de EDA descompuesta en su parte tónica (SCL) y su parte fásica (SCR). Fuente: [12].

2.5. Electromiograma (EMG)

El Electromiograma (EMG) registra la **actividad eléctrica que producen los músculos** cuando reciben señales de las neuronas motoras. Cuando un músculo está relajado no debería mostrar apenas actividad, pero en cuanto se contrae aparece una **señal cuya intensidad es proporcional al esfuerzo que se está haciendo** [13]. Este dato es útil porque **la tensión muscular suele subir cuando el sistema nervioso autónomo se activa** [14], así que complementa al resto de señales a la hora de analizar el estrés.

Tal como se muestra en la Figura 2.3, en reposo la actividad eléctrica es casi plana, mientras que **durante la contracción aumenta de forma considerable tanto en amplitud como en frecuencia**, y ese aumento está relacionado con el esfuerzo muscular realizado.




Figura 2.3 Señal de EMG en reposo frente a la señal registrada durante una contracción muscular. Fuente: [15].

2.6. Fotopletismografía (PPG) y Volumen de Pulso Sanguíneo (BVP)

La PPG y el Volumen de Pulso Sanguíneo (BVP) están estrechamente relacionados, pero no son exactamente lo mismo. La PPG es la **técnica de medición óptica**: consiste en iluminar la piel con un LED y medir los cambios en la absorción o reflexión de esa luz. El BVP, en cambio, es el **fenómeno fisiológico** que esa técnica capta, es decir, la variación del volumen de sangre que se produce en los vasos periféricos con cada latido del corazón. Dicho de otro modo, la PPG es el método con el que se registra la señal y el BVP es lo que realmente se está midiendo [16]. **A cada latido aparece un pico en la señal, y a partir de la diferencia temporal entre esos picos se puede obtener la frecuencia cardíaca** y también la Variabilidad de la Frecuencia Cardíaca (HRV).

Como puede verse en la Figura 2.4, en cada ciclo cardíaco aparece primero un pico principal (*el sistólico*), después una pequeña muesca (*la escotadura dicrótica*) y por último un segundo pico algo más pequeño (*el diastólico*). Esa forma de onda tan característica refleja cómo se mueve la sangre por los vasos periféricos.




Figura 2.4 Forma de onda de una señal PPG/BVP, con el pico sistólico, la escotadura dicrótica y el pico diastólico marcados. Fuente: [17].

2.7. Frecuencia Cardíaca (HR) e Intervalos RR

La Frecuencia Cardíaca (HR) representa el **número de latidos por minuto**, y en una persona en reposo se considera normal que este valor se sitúe entre 60 y 100 lpm [18]. El RR es un parámetro que mide el **tiempo que pasa entre un latido y el siguiente** tomando como referencia sus picos R, y la secuencia de intervalos RR es precisamente la base sobre la que se calcula la HRV. Tanto la HR como los intervalos RR cambian cuando hay estrés o cuando la carga cognitiva sube, así que en este trabajo se han usado como uno de los indicadores principales de activación del sistema autónomo.

En la Figura 2.5 se ve cómo el tiempo entre latidos no es exactamente igual siempre, sino que varía de forma continua, y esa variación es justo la que se relaciona con el estado de activación del sistema nervioso autónomo de la persona bajo estudio.




Figura 2.5 Variabilidad del ritmo cardíaco a lo largo de una serie de latidos consecutivos. Fuente: [18].

La Ecuación (2.1) relaciona la frecuencia cardíaca, expresada en latidos por minuto, con el intervalo RR medido en segundos:

$$HR \text{ (lpm)} = \frac{60}{RR \text{ (s)}} \quad (2.1)$$

Más allá del valor medio de la frecuencia cardíaca, el estudio de la **variabilidad de la frecuencia cardíaca** (HRV) analiza las pequeñas fluctuaciones que se producen entre intervalos RR consecutivos. Estas variaciones reflejan la actividad del **sistema nervioso autónomo** y, en particular, el equilibrio entre sus ramas simpática y parasimpática, por lo que constituyen un indicador útil del estado fisiológico del sujeto y de su respuesta al estrés [19].

Entre los numerosos parámetros propuestos para cuantificar la HRV (véase la Tabla 1 de [19]), uno de los más empleados en el dominio temporal es el Root Mean Square of Successive Differences (RMSSD). Se calcula como la raíz cuadrada de la media de los cuadrados de las diferencias entre intervalos RR sucesivos, según la Ecuación (2.2):

$$RMSSD = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2} \quad (2.2)$$

donde N es el número de intervalos RR considerados. Su uso está tan extendido porque es **sencillo de calcular**, resulta **robusto en registros de corta duración** y refleja principalmente la *actividad parasimpática (vagal)*, que tiende a disminuir en situaciones de estrés. Por ello, un descenso del RMSSD suele asociarse a una reducción del tono vagal característica de la respuesta de estrés [20].

2.8. Respiración (RESP)

La respiración consiste en el **intercambio de gases del organismo con el exterior**, y la Señal Respiratoria (RESP) recoge el movimiento mecánico del tórax en cada ciclo de inspiración y espiración. En condiciones normales se suele respirar entre 12 y 18 veces por minuto [21]. **Tanto el ritmo como el patrón respiratorio cambian cuando el sujeto está bajo estrés** o tiene una carga cognitiva alta, por lo que esta señal se ha incluido como un indicador más dentro del conjunto de datos.

Como se observa en la Figura 2.6, **el volumen pulmonar sube durante la inspiración hasta llegar a un pico y luego baja durante la espiración** hasta un valle, repitiéndose ese patrón de forma más o menos regular a lo largo del tiempo.




Figura 2.6 Ciclo respiratorio, mostrando las fases de inspiración y espiración junto al volumen pulmonar asociado. Fuente: [22].

2.9. Temperatura Cutánea y Temperatura Periférica (SKT/TEMP)

La Temperatura Cutánea (SKT) y la Temperatura Periférica (TEMP) dan una idea de **cómo está circulando la sangre por la superficie del cuerpo**, algo que también depende del sistema nervioso autónomo simpático. **Cuando hay estrés, los vasos periféricos se contraen (vasoconstricción) y la temperatura en esas zonas baja**; en cambio, cuando el cuerpo está relajado los vasos se dilatan y la temperatura sube [23].

Se puede apreciar en la Figura 2.7 que la temperatura periférica no se mantiene constante, sino que va cambiando con el tiempo, y esos cambios están relacionados con cómo varía la perfusión sanguínea en la piel según el estado del sistema nervioso autónomo.




Figura 2.7 Evolución de la temperatura periférica a lo largo del día. Fuente: [24].

2.10. Biopac

El sistema *BIOPAC* es una **plataforma de adquisición de datos biomédicos** ampliamente utilizada en investigación para el registro sincronizado de señales fisiológicas. El sistema está formado por una **unidad principal de adquisición de datos y un conjunto de sensores y accesorios** que permiten medir diferentes variables fisiológicas, como la actividad cardíaca (ECG), la respuesta electrodérmica (EDA), la respiración o la temperatura corporal, entre otras [25].

La Figura 2.8 muestra la unidad principal de adquisición (*BIOPAC MP35*), encargada de recibir las señales procedentes de los distintos sensores, digitalizarlas y transmitirlos al ordenador para su almacenamiento y posterior análisis. Esta unidad constituye el núcleo del sistema y permite la adquisición simultánea de múltiples canales con una elevada frecuencia de muestreo, garantizando una sincronización precisa entre todas las señales registradas.



Figura 2.8 Unidad de adquisición de datos BIOPAC MP35 empleada en el estudio.

La Figura 2.9 muestra el conjunto de accesorios utilizados junto con la unidad de adquisición, incluyendo los cables de conexión, los electrodos y el cinturón respiratorio. Estos elementos permiten registrar las diferentes señales fisiológicas de los participantes durante la realización de los experimentos.



Figura 2.9 Sensores y accesorios del sistema BIOPAC, incluyendo el cableado, los electrodos y el cinturón respiratorio.

En este trabajo, los registros obtenidos mediante el sistema BIOPAC se almacenan en la carpeta Biopac data.

2.11. Empatica E4

La pulsera *Empatica E4* es un **dispositivo portátil** diseñado para la **adquisición continua de señales fisiológicas de forma no invasiva**. Su reducido tamaño y facilidad de uso permiten registrar datos tanto en entornos controlados de laboratorio como en situaciones de la vida cotidiana, siendo una herramienta ampliamente empleada en investigaciones relacionadas con el reconocimiento de emociones, el estrés y el comportamiento humano [26].

El dispositivo integra diferentes sensores que permiten adquirir múltiples variables fisiológicas de manera simultánea. En concreto, incorpora un sensor de actividad electrodérmica (EDA), un sensor fotopletismográfico (PPG) para la obtención de la frecuencia cardíaca y los intervalos entre latidos, un sensor de temperatura cutánea mediante termopila infrarroja y un acelerómetro triaxial para registrar el movimiento del usuario. **Estas señales se registran con diferentes frecuencias de muestreo adaptadas a cada sensor**, permitiendo obtener **información fisiológica sincronizada** durante toda la sesión experimental [26].

La Figura 2.10 muestra la pulsera *Empatica E4* utilizada en este trabajo. Durante la adquisición de datos, el dispositivo se coloca en la muñeca no dominante del participante para minimizar las interferencias producidas por el movimiento, registrando de forma continua las diferentes señales fisiológicas. Posteriormente, **los datos almacenados en la memoria interna del dispositivo se descargan para su preprocesamiento y análisis**.



Figura 2.10 Pulsera Empatica E4 utilizada para la adquisición de señales fisiológicas.

En este trabajo, los registros obtenidos mediante la pulsera Empatica E4 se almacenan en la carpeta *Empatica data*.

2.12. De la evaluación subjetiva del estrés a los biomarcadores fisiológicos

Durante mucho tiempo, la forma habitual de medir el estrés ha sido a través de **cuestionarios, entrevistas clínicas y tests psicométricos**. El problema es que este tipo de herramientas tiene limitaciones claras: entran en juego sesgos como el de **deseabilidad social** (la persona responde lo que cree que “debería” responder) o simplemente **fallos de memoria**, y además **solo recogen la parte del estrés de la que el sujeto es consciente**, dejando fuera todo lo que ocurre a nivel fisiológico sin que la persona se dé cuenta [27]. De hecho, se calcula que **existen más de 150 cuestionarios distintos para medir el estrés**, lo cual da una pista de que **no hay un consenso muy claro sobre cómo definirlo ni cómo medirlo correctamente**.

Frente a esto, usar **biomarcadores fisiológicos permite medir el estrés de forma continua** y con datos cuantificables, sin depender de lo que la persona diga o recuerde. Estos biomarcadores están relacionados con dos sistemas de regulación del cuerpo: Eje Simpático-Adrenomedular (SAM), que responde casi al instante liberando catecolaminas, y el Eje Hipotálamo-Hipófiso-Adrenal (HHA), que actúa más despacio a través del cortisol [27]. Señales como el ECG o la TEMP, que son consideradas en este trabajo, están directamente relacionadas con la activación de esos dos ejes, y por ello se ha optado por usarlas como base para detectar el estrés de forma automática con aprendizaje automático.

2.13. Aprendizaje automático: conceptos básicos

El aprendizaje automático (Machine Learning (ML)) es una **rama de la inteligencia artificial** que se dedica a **diseñar técnicas para que los ordenadores puedan aprender a partir de datos**, sin necesidad de que alguien les programe de forma explícita qué hacer en cada situación. Se dice que

un sistema “aprende” cuando su rendimiento mejora a medida que va procesando más experiencia o más datos [28]. En vez de seguir reglas fijas escritas a mano, estos modelos construyen su propia representación a partir de lo que han observado, y la usan tanto para entender el problema como para resolverlo.

Hoy en día el aprendizaje automático se usa en una gran cantidad de ámbitos: buscadores, diagnóstico médico, detección de fraude, reconocimiento de voz, robótica, etc. [28]. En concreto, dentro del campo biomédico resulta especialmente útil porque **permite encontrar patrones en señales fisiológicas que serían muy difíciles de detectar a simple vista**, lo que lo convierte en una **herramienta bastante adecuada para este tipo de proyectos**.

De forma general, se puede dividir en tres grandes grupos:

- **Aprendizaje supervisado:** se entrena con datos que ya vienen etiquetados, de manera que el modelo aprende a asociar cada entrada con la salida correcta. Dentro de este grupo se distingue entre clasificación (cuando la salida es una categoría) y regresión (cuando la salida es un valor continuo).
- **Aprendizaje no supervisado:** aquí no hay etiquetas, y lo que se busca es encontrar patrones o agrupaciones ocultas dentro de los datos sin que nadie le diga al modelo qué buscar exactamente.
- **Aprendizaje por refuerzo:** un agente va tomando decisiones dentro de un entorno y recibe recompensas o penalizaciones según el resultado de esas decisiones, con el objetivo de ir mejorando su comportamiento con el tiempo.

En este trabajo se ha optado por el **aprendizaje supervisado**. En concreto, se han utilizado cuatro algoritmos: Random Forest (RF), Light Gradient Boosting Machine (LightGBM), Support Vector Machine (SVM) y K-Nearest Neighbours (KNN) [29]. Se explican con más detalle en los siguientes apartados.

2.14. Random Forest (RF)

El método RF (o bosques aleatorios) es un algoritmo de aprendizaje supervisado propuesto por *Leo Breiman* y *Adele Cutler* que se basa en combinar árboles de decisión entrenados por separado [30]. La idea de fondo es sencilla: **un árbol de decisión por sí solo puede tener ruido, pero si se hace la media de varios árboles distintos, ese ruido se reduce y el resultado final es más fiable**.

Cada árbol se entrena con una muestra aleatoria de los datos, y en cada nodo **se elige solo un subconjunto aleatorio de variables** para decidir cómo dividir. A la hora de clasificar un dato nuevo, este pasa por todos los árboles del conjunto y se queda con la clase que más veces se repita entre todas las predicciones [30]. Esto **hace que el modelo generalice mejor** y sea **menos propenso al sobreajuste que un árbol único**, además de ser **robusto** frente a valores atípicos y de no necesitar que los datos estén normalizados de antemano. En este trabajo, Random Forest se ha usado como el **algoritmo principal**, ya que se adapta bien a trabajar con señales fisiológicas de tipos muy distintos entre sí.

En la Figura 2.11 se ve cómo cada árbol da su propio resultado por separado, y al final se elige la clase que más votos ha recibido entre todos ellos, lo cual hace que el modelo en conjunto sea más estable que cualquiera de los árboles individuales.




Figura 2.11 Funcionamiento de Random Forest: una muestra nueva pasa por varios árboles de decisión independientes y la predicción final se decide por votación mayoritaria o promediado. Fuente: [31].

2.15. Light Gradient Boosting Machine (LightGBM)

El LightGBM es una técnica que construye árboles de decisión de forma secuencial, de modo que cada árbol nuevo corrige los errores cometidos por los anteriores. Fue desarrollado por Microsoft y publicado como código abierto [32]. Se diferencia de otras implementaciones de *boosting* en que no construye los árboles nivel a nivel, sino hoja a hoja: en cada paso escoge la hoja que mejor reduce la pérdida y sigue creciendo por ahí. Además, a diferencia de otros métodos, ordena los datos **utilizando un enfoque basado en histogramas**, lo que proporciona la mayor velocidad y menor uso de memoria [32].

El algoritmo incorpora dos métodos que mejoran su rendimiento: el Gradient-Based One-Side Sampling (GOSS), que descarta los datos con gradientes pequeños porque se consideran poco informativos, reduciendo así el ruido; y el Exclusive Feature Bundling (EFB), que agrupa variables que casi nunca toman valores distintos de cero al mismo tiempo, reduciendo la dimensionalidad. En este trabajo, LightGBM se ha utilizado como alternativa a RF, aprovechando que funciona bien cuando hay muchas variables fisiológicas de entrada [32].

Como se ve en la Figura 2.12, a diferencia de otros métodos que van creciendo nivel a nivel de forma uniforme, LightGBM elige en cada iteración la hoja concreta que mejor reduce el error, lo que le permite llegar a modelos bastante precisos sin requerir tanto coste de cómputo.




Figura 2.12 Crecimiento hoja a hoja en LightGBM: en cada paso se expande la hoja que produce mayor reducción de la pérdida. Fuente: [32].

2.16. Support Vector Machine (SVM)

Las SVM o Máquinas de Vectores de Soporte son un conjunto de algoritmos de aprendizaje supervisado desarrollados por Vladimir Vapnik y su equipo en los laboratorios tAT&T Bell, y se pueden usar tanto para clasificación como para regresión [33]. La idea central es **buscar un hiperplano** (o un conjunto de hiperplanos) que separe las distintas clases de la mejor forma posible, maximizando la distancia entre el hiperplano y los puntos más cercanos a él, que son los llamados **vectores de soporte**. Por eso también se les conoce como clasificadores de margen máximo.

Cuando las clases no se pueden separar con una línea recta en el espacio original, **las SVM pueden proyectar los datos a un espacio de más dimensiones usando funciones kernel**, lo que permite encontrar fronteras de decisión no lineales [33]. Esto las hace bastante potentes cuando se trabaja con muchas variables a la vez, como pasa al combinar varias señales fisiológicas distintas, aunque a cambio pueden ser lentas de entrenar si el conjunto de datos es muy grande. En este trabajo se ha usado SVM como uno de los clasificadores, aportando un punto de vista distinto al de los modelos basados en árboles.

En la Figura 2.13 se muestra cómo SVM busca el hiperplano que deja el mayor margen posible entre las dos clases, siendo los vectores de soporte los puntos que están justo en el límite y que determinan dónde queda colocado ese hiperplano.




Figura 2.13 Funcionamiento de una SVM: hiperplano de separación óptimo, margen máximo y vectores de soporte de cada clase. Fuente: [33].

2.17. K-Nearest Neighbors (KNN)

KNN es un **algoritmo de aprendizaje supervisado** que se puede usar tanto para clasificación como para regresión, y que funciona a partir de una idea bastante intuitiva: **mirar qué tan parecido es un dato nuevo a los datos que ya se conocen**. Cada dato nuevo queda representado con el algoritmo busca los k puntos más cercanos dentro del conjunto de entrenamiento (normalmente usando la distancia euclídea) y le asigna la clase que más se repita entre esos vecinos [34]. El valor de k , esto es, el número de vecinos más próximos a considerar, es clave porque si es muy pequeño, el modelo se vuelve muy sensible al ruido, y si es muy grande las fronteras entre clases se suavizan demasiado.

Una particularidad de KNN es que no construye realmente un modelo durante el entrenamiento, sino que **se limita a guardar todos los datos y hace los cálculos en el momento de clasificar**; por eso se le llama algoritmo de aprendizaje perezoso (*lazy learner*) [34]. Su principal ventaja es que es sencillo y no asume nada sobre cómo se distribuyen los datos, aunque puede resultar lento con *datasets* grandes y depende bastante de si las variables están bien escaladas y de qué valor de k se elija. En este trabajo se ha incluido como modelo de referencia, para poder comparar su rendimiento frente a los algoritmos basados en árboles.

Como se observa en la Figura 2.14, el algoritmo localiza los k vecinos más próximos al punto nuevo y le asigna la clase que predomine entre ellos, siendo k el parámetro que más condiciona cómo se comporta el modelo.




Figura 2.14 Funcionamiento de KNN con $k = 3$: el nuevo punto se clasifica según la clase mayoritaria entre sus tres vecinos más cercanos. Fuente: [34].

3. Objetivos

3.1. Objetivo general

El objetivo de este TFG es desarrollar una aplicación de código abierto para la visualización y análisis simultáneo de señales fisiológicas multicanal, orientada a la identificación de períodos de estrés en sujetos sometidos a tareas de esfuerzo cognitivo bajo estímulos musicales de distinta naturaleza, integrando el preprocesado de las señales y modelos de aprendizaje automático que estiman la probabilidad de estrés.

3.2. Objetivos específicos

- Estudiar y comprender la estructura y contenido del dataset *A Multimodal Dataset for Investigating Working Memory in Presence of Music* [6], incluyendo las señales fisiológicas registradas y el protocolo experimental empleado.
- Implementar módulos de carga, preprocesamiento y sincronización temporal de las señales fisiológicas presentes en el dataset, concretamente ECG, EDA, PPG, intervalos RR y Latidos Por Minuto (BPM).
- Desarrollar una interfaz de usuario que permita la visualización simultánea y dinámica de las señales fisiológicas, facilitando la exploración temporal de los datos registrados.
- Diseñar e implementar métodos de análisis que permitan detectar y representar visualmente los puntos de estrés del sujeto a partir de la información combinada de las señales.
- Validar el funcionamiento de la aplicación con los datos del *dataset*, verificando la coherencia de los resultados obtenidos con el protocolo experimental definido.
- Evaluar la robustez y flexibilidad del sistema aplicándolo sobre una base de datos distinta a la empleada durante su desarrollo, con el fin de comprobar su capacidad de generalización ante datos ajenos al conjunto original.
- Garantizar la reproducibilidad del *software* desarrollado mediante la publicación del código fuente bajo una licencia de acceso abierto.

4. Metodología

4.1. Base de datos: *A Multimodal Dataset for Investigating Working Memory in Presence of Music*

El dataset empleado en el presente trabajo es el conjunto de datos público *A Multimodal Dataset for Investigating Working Memory in Presence of Music* [1], publicado en **PhysioNet** en febrero de 2025. Este conjunto de datos multimodal fue desarrollado con el objetivo de investigar la *viabilidad de la música como intervención no invasiva para regular los estados de arousal cognitivo y el rendimiento durante tareas de memoria de trabajo*.

4.1.1. Protocolo experimental

El experimento se diseñó en torno a la tarea cognitiva denominada *n-back* (como se observa en la Figura 4.1), en la que el participante debe identificar si el estímulo mostrado actualmente coincide con el presentado n iteraciones anteriores, incrementando la carga cognitiva con el valor de n [35]. El experimento constó de *dos sesiones de aproximadamente 16 minutos* cada una: la primera acompañada de **música calmante** y la segunda de **música estimulante**, seleccionadas por los propios participantes para garantizar la validez ecológica del estudio.




Figura 4.1 Representación de tareas cognitivas *n-back*. Fuente: [35]

Cada sesión incluyó **16 bloques de tareas** (8 bloques de tarea 1-back y 8 bloques de tarea 3-back), distribuidos aleatoriamente. Cada bloque constaba de 22 ensayos, con una duración total de 49 segundos por bloque. Entre bloques se introdujeron ventanas de relajación de 10 segundos, y tras los primeros 8 bloques de cada sesión se incluyó un periodo de descanso de 20 segundos.

Originalmente participaron 11 sujetos en el experimento. Sin embargo, tras eliminar aquellos con modalidades incompletas o datos corruptos, el conjunto de datos definitivo **comprende 5 participantes** (2 hombres y 3 mujeres) con edades comprendidas entre 22 y 25 años [35].

4.1.2. Señales registradas

Las señales fisiológicas fueron adquiridas mediante dos sistemas de medida complementarios: el sistema Biopac MP160, orientado a la adquisición de alta resolución en entorno de laboratorio, y el dispositivo Empatica E4, diseñado para la monitorización ambulatoria no intrusiva mediante sensores de muñeca.

El conjunto de señales registradas se resume en la Tabla 4.1.

Tabla 4.1 Señales fisiológicas registradas en el dataset y dispositivos empleados.

Señal	Dispositivo	Frecuencia de muestreo
ECG	Biopac MP160	2000 Hz
EDA	Biopac MP160 / Empatica E4	2000 Hz / 4 Hz
PPG (BVP)	Biopac MP160 / Empatica E4	2000 Hz / 64 Hz
EMG	Biopac MP160	2000 Hz
RESP	Biopac MP160	2000 Hz
SKT (TEMP)	Biopac MP160 / Empatica E4	2000 Hz / 4 Hz
HR	Empatica E4	1 Hz
Acelerometría (ACC)	Empatica E4	32 Hz

Adicionalmente, la base de datos utilizada como referencia principal incluye una **representación visual de los dispositivos empleados durante la adquisición de las señales fisiológicas**. Esta imagen permite apreciar la disposición de los diferentes sensores sobre el participante y facilita la comprensión del proceso de recopilación de datos seguido en el estudio. La Figura 4.2 muestra dicha distribución de los dispositivos.

En la Figura 4.2 también se puede observar la Figura 4.1, ya que dicha representación fue extraída de la misma fotografía.




Figura 4.2 Disposición de los dispositivos utilizados para la adquisición de señales fisiológicas en el estudio correspondiente a la base de datos principal empleada en este Trabajo de Fin de Grado. Fuente: [35].

4.1.3. Estructura y acceso a los datos

Los datos se organizan en carpetas por tipo de señal y dispositivo: *Biopac data*, *Empatica data*, *fNIRS data*, *Face reader data* y *Behavioral data*. En este trabajo se utilizarán únicamente las carpetas *Biopac data* y *Empatica data*, ya que contienen las señales fisiológicas objeto de análisis. Las restantes corresponden a modalidades de datos -Espectroscopía Funcional de Ingarrojo Cercano (fNIRS), reconocimiento facial y datos conductuales que quedan fuera del alcance de este estudio.

Los archivos se almacenan en formato Comma-Separated Values (CSV), con una nomenclatura que incluye el número de sujeto, el género y el tipo de señal. El dataset está disponible públicamente en **PhysioNet** bajo la licencia *Open Data Commons Attribution License v1.0*, con un tamaño total descomprimido de 1.6 GB [1].

Como paso previo al procesamiento, los datos se reorganizaron en una estructura de carpetas por participante y por tipo de señal. Esta organización facilita el acceso a los archivos y permite que la aplicación identifique automáticamente a cada sujeto a partir de la estructura de directorios.

4.2. Entorno de desarrollo

El desarrollo del proyecto se llevó a cabo íntegramente en **Python** [36], lenguaje ampliamente utilizado en el ámbito del procesamiento de señales biomédicas y el aprendizaje automático, gracias a su ecosistema de librerías científicas y a su facilidad de integración con herramientas de visualización y desarrollo de interfaces gráficas [28].

El editor de código empleado fue **Visual Studio Code (VSC)** [37], debido a su integración con entornos virtuales de **Python**, su soporte para la depuración interactiva y su compatibilidad con un amplio conjunto de extensiones orientadas al desarrollo científico.

El control de versiones del proyecto se gestionó mediante un repositorio alojado en **GitHub** [38], disponible en <https://github.com/raquelgomez2003/Trabajo-de-Fin-de-Grado/tree/main/BioVisor>. El uso de este repositorio permitió registrar y gestionar de forma ordenada las distintas versiones del código, facilitando el seguimiento de los cambios realizados durante el desarrollo de la aplicación.

Las principales librerías empleadas para la realización de este TFG son las descritas en la Tabla 4.2.

Tabla 4.2 Principales librerías de **Python** empleadas en el desarrollo de **BioVisor**.

Librería	Uso en la aplicación
<code>numpy</code>	Procesamiento numérico y manipulación de arrays de señales fisiológicas.
<code>pandas</code>	Lectura y parsing de archivos CSV de señales y tiempos de sesión, con soporte para distintos separadores y codificaciones.
<code>matplotlib</code>	Representación gráfica de señales, boxplots, curvas ROC, mapas de calor y probabilidades de estrés. Integración mediante <code>backend_tkagg</code> .

<code>scipy.signal</code>	Filtrado de señales fisiológicas (<code>butter</code> , <code>filtfilt</code>) y detección de picos RR en el ECG (<code>find_peaks</code>).
<code>customtkinter</code>	Desarrollo de la interfaz gráfica de usuario, proporcionando componentes modernos sobre <code>tkinter</code> : ventanas, botones, entradas, pestañas y marcos desplazables.
<code>scikit-learn</code>	Implementación de los clasificadores RF (<code>RandomForestClassifier</code>), SVM (<code>SVC</code>) y KNN (<code>KNeighborsClassifier</code>); preprocesado (<code>StandardScaler</code> , <code>SimpleImputer</code>); construcción de pipelines; y cálculo de métricas de evaluación (<code>roc_curve</code> , <code>auc</code>).
<code>lightgbm</code>	Implementación del clasificador LightGBM (<code>LGBMClassifier</code>).
<code>joblib</code>	Serialización y carga eficiente de modelos entrenados mediante almacenamiento en disco.

4.3. Preprocesamiento de señales

Antes de proceder al análisis de las señales fisiológicas, es necesario aplicar una **serie de etapas de preprocesamiento** que garanticen la calidad y coherencia de los datos. Las señales biomédicas presentan características particulares que condicionan su tratamiento: diferencias en la frecuencia de muestreo entre dispositivos, gran volumen de datos, presencia de artefactos y necesidad de sincronización temporal entre canales.

Por tanto, en esta sección se describen las etapas de preprocesamiento aplicadas a los datos con el fin de obtener un conjunto de señales homogéneas y adecuadas para su posterior análisis y visualización.

4.3.1. Carga de datos

Las señales del sistema Biopac se almacenan en formato CSV sin cabecera, con una **frecuencia de muestreo de 2000 Hz** y más de cinco millones de muestras por señal y sujeto. La carga se realiza mediante la librería `pandas`, con soporte automático para distintos separadores de columna. En archivos con varias columnas se selecciona automáticamente aquella con mayor varianza, que corresponde a la señal fisiológica de interés.

Las señales del dispositivo **Empatica E4** siguen un formato propio: la primera fila contiene el instante de inicio en tiempo **Unix**, la segunda indica la frecuencia de muestreo nominal, y los datos comienzan a partir de la tercera fila. Las frecuencias de muestreo varían entre 1 Hz para la HR y 64 Hz para el BVP (Tabla 4.2). La ACC se almacena en tres columnas correspondientes a los ejes **X**, **Y** y **Z**, de las que se calcula la magnitud resultante $\|\mathbf{a}\| = \sqrt{x^2 + y^2 + z^2}$.

4.3.2. Eliminación de artefactos

Las señales fisiológicas pueden presentar **saltos abruptos entre muestras consecutivas** debidos a artefactos de **movimiento**, **desconexiones momentáneas** del sensor o **interferencias eléctricas**. Para su detección se emplea un criterio relativo basado en la mediana de las diferencias consecutivas de la señal: **una muestra se considera artefacto si su variación respecto a la muestra anterior supera un factor multiplicativo que depende del tipo de señal**. Este enfoque es independiente de las unidades de medida y se adapta automáticamente a la amplitud de cada señal.

El umbral se define de forma específica para cada tipo de señal. Las señales cardíacas como **el ECG y el BVP tienen umbrales más permisivos (factor 500)** para evitar que los picos RR sean eliminados por error. **Las señales lentas como la temperatura cutánea emplean umbrales más estrictos (factor 20)**, dado que no pueden presentar variaciones bruscas en condiciones normales. Las muestras marcadas como artefacto se sustituyen mediante interpolación lineal entre los valores válidos adyacentes, preservando la longitud de la señal y la validez del eje temporal.

4.3.3. Segmentación por sesión

El *dataset* proporciona para cada sujeto un archivo denominado **Triggers_block.csv**, que contiene los puntos de muestreo exactos en los que comienza y termina cada tarea realizada durante la sesión experimental.

A partir de estos valores convertidos se identifican los periodos correspondientes a la música calmante y a la música estresante, tomando el valor mínimo y máximo de cada sección como instantes de inicio y fin del intervalo. Con esta información se genera para cada sujeto un archivo **SubjectN_Session_Times.csv**, que recoge los cuatro instantes temporales necesarios para la aplicación: **inicio y fin de la fase calmante, e inicio y fin de la fase estresante**. Este archivo es el que carga automáticamente la aplicación al seleccionar un sujeto, tal como se describió en la Sección 4.3.

Los tiempos de sesión se emplean con dos finalidades en la aplicación: por un lado, para la **representación visual en la interfaz gráfica**, donde cada fase aparece sombreada con un color distinto sobre las señales y por otro, como **referencia para el etiquetado de las ventanas de análisis** durante la estimación de la probabilidad de estrés.

4.4. Diseño del sistema de detección de estrés

La Figura 4.3 muestra el **pipeline o flujo completo del sistema**, desde la carga de las señales hasta la obtención de la probabilidad de estrés.

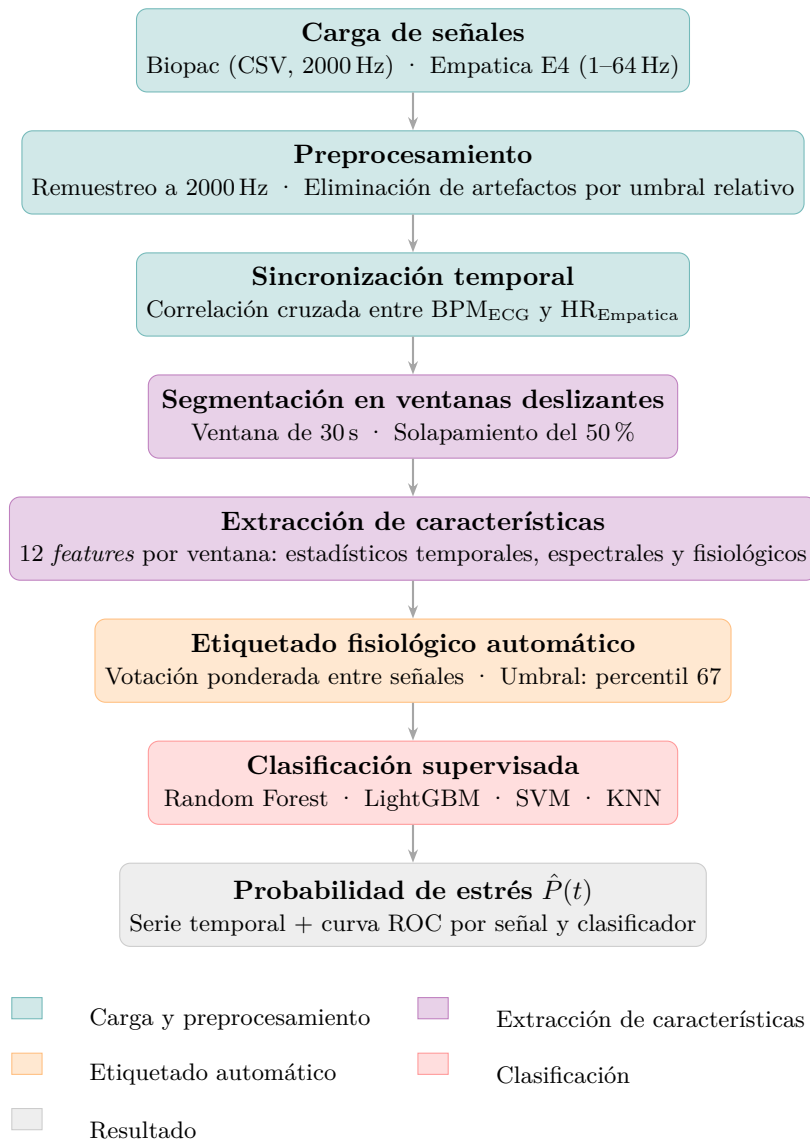


Figura 4.3 *Pipeline* completo de detección de estrés implementado en BioVisor. Cada bloque corresponde a una etapa del proceso, desde la carga de las señales fisiológicas hasta la estimación de la probabilidad de estrés a lo largo del tiempo.

El **núcleo analítico de la aplicación** es un pipeline de procesamiento que opera sobre las señales fisiológicas multicanal para estimar automáticamente la probabilidad de estrés del sujeto a lo largo del tiempo. Dado que el *dataset* no proporciona etiquetas de estrés explícitas, **el sistema genera sus propias etiquetas a partir de indicadores fisiológicos objetivos extraídos de las propias señales**, sobre las que entrena posteriormente un clasificador supervisado.

4.4.1. Normalización de los datos

Antes de entrenar los clasificadores, las características extraídas de cada ventana se **normalizan**. Este paso resulta determinante por tres motivos: acelera la **convergencia** del modelo durante el entrenamiento, evita el *sesgo* que introducirían las características con mayor rango dinámico —que de otro modo dominarían frente a las de menor escala—, y garantiza un modelo final más **robusto** ante

datos nuevos no vistos durante el ajuste.

La técnica empleada es la **estandarización z -score**, que transforma cada característica para que presente media nula y desviación típica unidad:

$$z = \frac{x - \mu}{\sigma}, \quad (4.1)$$

donde x es el valor original de la característica y μ y σ son, respectivamente, la media y la desviación típica estimadas sobre el conjunto de entrenamiento. La normalización se aplica de forma independiente a cada una de las características de ventana (*Mean*, *Std*, *RMS* y *PtP*) y por igual para todas las señales analizadas (ECG, EDA, EMG, PPG, RESP, SKT, etc.).

En **BioVisor** la estandarización se integra en una *tubería* de procesamiento (**Pipeline**) que encadena tres etapas en orden fijo:

1. **Imputación de valores ausentes** (**SimpleImputer**). Los valores no disponibles de cada característica se sustituyen por la *mediana* de esa columna, más robusta frente a valores atípicos que la media. De este modo se asegura que la etapa siguiente reciba una matriz de características completa.
2. **Estandarización z -score** (**StandardScaler**). Se aplica la transformación de la ecuación (4.1) a cada característica.
3. **Clasificación**, con el modelo seleccionado (*Random Forest*, *LightGBM*, SVM o KNN).

Un aspecto clave es que los estadísticos μ y σ (y la mediana de la imputación) se calculan **únicamente con las ventanas de entrenamiento** y después se aplican al resto del registro. Con ello se impide la *fuga de información* (*data leakage*) del conjunto de prueba hacia el ajuste del modelo: en la generación de la probabilidad de estrés sobre todo el registro, el escalador ajustado con las ventanas etiquetadas se emplea para transformar la totalidad de las ventanas; y en la validación cruzada empleada para la curva ROC, la *tubería* completa se reajusta en cada partición usando solo su subconjunto de entrenamiento.

Esta normalización es especialmente relevante para los clasificadores basados en *distancias* o *núcleos*, como KNN y SVM, cuyo rendimiento se degrada si las características no comparten una escala común; aunque los modelos de árboles (*Random Forest*, *LightGBM*) son menos sensibles a la escala, la estandarización se aplica de manera uniforme a todos ellos para garantizar un tratamiento homogéneo.

4.4.2. Segmentación en ventanas deslizantes

Para analizar las señales, estas se dividen en **ventanas de 60 segundos** con un solapamiento del 50 %, lo que significa que **cada nueva ventana comienza 30 segundos después de la anterior**. Se ha elegido este tamaño porque ofrece un *buen equilibrio entre el nivel de detalle del análisis y la fiabilidad* de las características que se extraen de cada segmento.

Si las ventanas fueran demasiado cortas, por ejemplo de 10 segundos, algunas características relacionadas con la variabilidad de la frecuencia cardíaca no podrían calcularse con suficiente precisión, ya que habría muy pocos latidos para obtener un resultado representativo [19]. Por el contrario, utilizar ventanas demasiado largas reduciría la capacidad de detectar cambios rápidos en el estado fisiológico del sujeto, ya que cada ventana abarcaría un periodo de tiempo mayor.

El solapamiento del 50 % permite que el análisis sea continuado entre ventanas consecutivas y mejora el seguimiento de la evolución de las señales a lo largo del experimento.

En cualquier caso, tanto el tamaño de la ventana como el porcentaje de solapamiento pueden modificarse desde la propia aplicación. De esta forma, el usuario puede adaptar estos parámetros a las características de las señales analizadas o al protocolo experimental que esté utilizando.

4.4.3. Extracción de características

Por cada ventana temporal se extrae un vector de 12 características que describe el comportamiento de la señal en ese intervalo. Las ocho primeras son estadísticos de carácter general aplicables a cualquier señal: **media**, **desviación típica**, **Valor Cuadrático Medio (RMS)**, **valor pico a pico**, **asimetría (*skewness*)**, **curtosis**, **potencia en baja frecuencia** y **potencia en alta frecuencia**, calculadas estas dos últimas sobre el espectro de amplitud de la señal enventanada.

Las cuatro características restantes son específicas del tipo de señal. Para las señales cardíacas ECG y BVP, corresponden a parámetros de variabilidad de la HRV:

- **BPM medio**: frecuencia cardíaca media calculada a partir de los intervalos RR detectados en la ventana.
- **RMSSD**: mide la variabilidad entre intervalos RR consecutivos y refleja la actividad del sistema nervioso parasimpático.
- **Ratio Low Frequency (LF)/High Frequency (HF)**: cociente entre la potencia espectral en la banda de baja frecuencia (0.04–0.15 Hz) y la de alta frecuencia (0.15–0.40 Hz), que cuantifica el balance entre la actividad simpática y parasimpática del sistema nervioso autónomo.
- **Porcentaje de Intervalos NN que difieren más de 50 ms (pNN50)**: proporción de intervalos RR consecutivos que difieren en más de 50 ms, relacionado con la actividad vagal.

Para la RESP se calculan la *frecuencia respiratoria en respiraciones por minuto*, la amplitud del ciclo y la irregularidad del patrón respiratorio. Para la EDA se extraen el nivel de conductancia tónica (SCL), el número de respuestas fásicas (SCR) y su desviación típica. Para el electromiograma (EMG) se obtienen el RMS de la señal filtrada en alta frecuencia y el valor absoluto medio de la derivada. Para la temperatura cutánea (TEMP) se emplean la temperatura media, la tendencia térmica a lo largo de la ventana y su variabilidad.

4.4.4. Etiquetado fisiológico por votación ponderada

Los *dataset* utilizados **no incluyen etiquetas de estrés directas**, es decir, no indican en qué momentos exactos el sujeto estaba realmente estresado. Por eso, uno de los principales aportes de nuestro sistema es que **genera esas etiquetas de forma automática** a partir de la propia respuesta fisiológica de cada persona. La idea es que sea la **información fisiológica** la que permita identificar los estados de estrés de manera objetiva y personalizada.

Para poder hacer esto, la aplicación necesita saber en qué intervalos de tiempo ocurre cada condición del experimento (las fases de *calming* y *vexing*). Esa información se obtiene del **archivo de tiempos de sesión** si el usuario dispone de él; la aplicación lo carga automáticamente al seleccionar el sujeto.

Si no, los intervalos pueden introducirse a mano desde el panel lateral de la interfaz (la cual se explica más en profundidad en la sección siguiente).

El proceso funciona en dos pasos. Primero, **para cada señal se calcula una puntuación de estrés normalizada** a partir de las características extraídas, de modo que cada señal aporte su propia visión del nivel de activación del sujeto. Esa puntuación se construye de forma distinta según lo que mide cada señal: en el ECG y el BVP combina el BPM medio, el RMSSD invertido y el ratio LF/HF; en la EDA se emplea el nivel de conductancia tónica; en la respiración, la frecuencia respiratoria; y en el EMG, la actividad muscular. A partir de esta puntuación, **una ventana recibe un «voto» de estrés de una señal cuando su valor supera el percentil 67 de esa misma señal** a lo largo de la sesión, es decir, cuando se sitúa en el **tercio superior** de activación fisiológica de ese sujeto.

En el segundo paso, la etiqueta definitiva de cada ventana se decide por **mayoría ponderada** entre los votos de todas las señales disponibles. No todas las señales pesan igual: las señales cardíacas (ECG, BVP y PPG) tienen el **doble de peso** que las demás, ya que son los marcadores de estrés más fiables y utilizados en la literatura [27]. Finalmente, **si la suma ponderada de los votos positivos supera la mitad del peso total, la ventana se marca como estado de estrés**; en caso contrario, se etiqueta como ausencia de estrés.

Conviene tener presente que este método afronta una **limitación del dataset**. Al no contener unas etiquetas de estrés validadas de forma externa, el sistema no se puede ajustar comparando sus resultados con otros relacionados. Esto implica que **la calidad del etiquetado va a depender de lo intensa y constante que sea la respuesta** ante el estímulo desapacible, algo que está condicionado por la fisiología del sujeto.

4.4.5. Clasificadores empleados

Se implementan y comparan cuatro clasificadores supervisados de aprendizaje automático: RF, LightGBM, SVM y KNN. La selección de estos cuatro modelos sigue la misma línea metodológica adoptada en el TFG de Andrea Rojo [29], que analiza la detección de arritmias con estos mismos clasificadores.

Todos los clasificadores reciben como entrada el vector de características de cada ventana e intentan predecir su etiqueta de estrés. Antes del entrenamiento, las características se normalizan mediante normalización **z-score** y los valores ausentes se imputan con la mediana de cada columna (**SimpleImputer**), garantizando que todos los modelos reciben datos en el mismo rango y sin valores nulos.

RF emplea 50 árboles de decisión con una profundidad máxima de 6 niveles y ponderación de clases balanceada. Estos valores proporcionan un buen equilibrio entre capacidad de generalización, coste computacional y control del sobreajuste, además de compensar el posible desbalance entre clases.

LightGBM se configura con 100 estimadores, un valor suficiente para obtener un buen rendimiento sin aumentar innecesariamente el tiempo de entrenamiento.

En SVM se utiliza un kernel Función de Base Radial (RBF) con $C = 1$ y $\gamma = \text{scale}$, una configuración estándar que permite modelar relaciones no lineales de forma robusta. Se activa la estimación de probabilidades para calcular la curva ROC.

El clasificador KNN emplea los 5 vecinos más próximos, un valor que ofrece un buen compromiso entre robustez frente al ruido y capacidad de clasificación.

4.4.6. Evaluación del rendimiento (Diagrama de bloques, curvas ROC, AUC y validación cruzada)

El rendimiento de cada clasificador se evalúa mediante la curva ROC, que muestra de forma gráfica el compromiso entre la tasa de verdaderos positivos y la de falsos positivos a medida que se cambia el umbral de clasificación. Para resumir ese rendimiento en un solo número se utiliza el AUC: un valor de 0,5 indica que el clasificador acierta como si se clasificara al azar, mientras que un valor de 1,0 corresponde a una clasificación perfecta [29] [39].

Un aspecto **importante** de esta evaluación es que para la curva ROC se ha entrenado el modelo a partir de predicciones obtenidas por **validación cruzada**. De esta forma, cada ventana se evalúa siempre con un modelo nuevo durante su entrenamiento, evitando así la fuga de datos y obteniendo un AUC más honesto y representativo. Además, dado que las ventanas de análisis se solapan entre sí, la validación se realiza **agrupando ventanas contiguas por bloques temporales**, de modo que dos ventanas casi idénticas nunca acaben una en el conjunto de entrenamiento y otra en el de prueba, lo que mejoraría engañosamente el resultado del clasificador.

Para cada clasificador y cada señal la aplicación muestra el número de ventanas clasificadas como estrés respecto al total, la probabilidad media de estrés y la serie temporal completa de la probabilidad de estrés $\hat{P}(t)$. De esta forma resulta sencillo comparar directamente los resultados entre unos modelos y otros, y entre las distintas señales. Los resultados visuales obtenidos con el *pipeline* descrito se presentan en el Capítulo 5, donde se detalla la implementación de la aplicación y se muestran las representaciones generadas para cada sujeto del *dataset*.

4.5. Diseño de la aplicación

La aplicación **BioVisor** se diseña como una herramienta de escritorio desarrollada en Python, cuyo objetivo es facilitar el análisis y la visualización de señales fisiológicas mediante una interfaz gráfica intuitiva. Para su utilización es necesario disponer del entorno de ejecución y las dependencias correspondientes. Su arquitectura se organiza en torno a una ventana principal que integra dos módulos accesibles mediante un sistema de pestañas: **el módulo de visualización de señales y el módulo de análisis de estrés**. Ambos comparten un panel lateral de configuración común desde el que el usuario gestiona la sesión activa. La organización general de la interfaz se muestra en la Figura 4.4.



Figura 4.4 Esquema visual de la interfaz de BioVisor.

4.5.1. Pantalla de configuración inicial

Al iniciar la aplicación se presenta una ventana de configuración previa a la carga de datos. En ella el usuario especifica los siguientes parámetros:

- **Carpeta del dataset:** ruta a la carpeta raíz que contiene los datos de todos los sujetos. La aplicación construye automáticamente las rutas a las subcarpetas de cada sujeto (*Biopac data* o *Empatica_data*) a partir de esta ruta.
- **Tipo de dispositivo:** selección entre Biopac y Empatica E4 mediante botones de opción. Esta elección determina las señales disponibles, los formatos de archivo esperados y las frecuencias de muestreo por defecto.
- **Número de sujetos:** número de sujetos disponibles en el dataset, que determina los botones de selección de sujeto generados en el panel lateral.
- **Señales a cargar:** lista de señales disponibles para el dispositivo seleccionado, con casillas de verificación para incluir o excluir cada una. Para cada señal se puede especificar también su frecuencia de muestreo, que por defecto toma el valor nominal del dispositivo.

Una vez confirmada la configuración, la ventana principal se activa y queda lista para cargar sujetos.

4.5.2. Panel lateral y gestión de sujetos

El panel lateral izquierdo de la ventana principal centraliza los controles de la sesión. Desde este panel el usuario puede iniciar una nueva sesión de configuración, seleccionar el sujeto a analizar pulsando el botón correspondiente, y definir los intervalos temporales de las fases experimentales.

Al seleccionar un sujeto, la aplicación busca sus archivos de señales en la carpeta correspondiente y los carga mostrando un registro del proceso en un popup de progreso. Si existe un archivo `SubjectN_Session_Times.csv` en la carpeta del sujeto, los tiempos de inicio y fin de las fases calmante y estresante se rellenan automáticamente en los campos del panel lateral.

Los campos de tiempo de sesión pueden editarse manualmente en cualquier momento. El botón *Update Viewer* redibuja las señales con los nuevos intervalos de fase, y el botón *Reset App* limpia la sesión actual manteniendo la configuración del dataset para poder seleccionar otro sujeto sin necesidad de reiniciar la aplicación.

4.5.3. Módulo de visualización

El módulo de visualización permite explorar de forma interactiva las señales fisiológicas del sujeto seleccionado. Las señales se representan en subgráficas independientes apiladas verticalmente, con el eje temporal compartido de forma que el zoom o el desplazamiento horizontal se sincroniza automáticamente entre todos los paneles. Cuando el usuario realiza una operación de zoom, los límites del eje vertical de cada panel se ajustan de forma automática a los datos visibles en esa ventana temporal, de modo que la señal ocupa siempre el alto completo del panel sin espacios en blanco.

Las fases experimentales se distinguen mediante sombreado de color sobre el eje temporal: verde para la música calmante, amarillo para la fase estresante y rosa para los periodos de reposo. Esta codificación facilita la interpretación visual de las señales en el contexto del protocolo experimental. La barra de herramientas de navegación de matplotlib permite además realizar zoom, desplazamiento y exportación de las figuras.

4.5.4. Módulo de análisis

El módulo de análisis ejecuta el pipeline de detección de estrés descrito en la sección anterior y presenta los resultados de forma interactiva. El panel de controles lateral permite al usuario seleccionar las señales a analizar, los clasificadores a emplear (RF, LightGBM, SVM y KNN, de forma individual o combinada), el tamaño de ventana y el paso de solapamiento. Al pulsar el botón *Run Analysis*, el sistema ejecuta el pipeline para cada combinación de señal y clasificador, mostrando el progreso en el panel de estado.

Los resultados se organizan en un sistema de pestañas con una pestaña por señal analizada y una pestaña *Global*. Dentro de cada pestaña de señal, los resultados de cada clasificador se presentan en secciones desplegadas que el usuario puede expandir o colapsar, con las siguientes representaciones:

- **Distribución de características** (*boxplot*): diagrama de caja para cada una de las 12 características extraídas, separadas por fase experimental (calmante, estresante y reposo), que permite visualizar si las características presentan diferencias significativas entre fases.
- **Curva ROC**: curva con el valor del AUC y el umbral óptimo de clasificación, calculados comparando las predicciones del modelo con los intervalos de sesión definidos por el usuario.
- **Probabilidad de estrés temporal**: evolución de la probabilidad de estrés $\hat{P}(t)$ a lo largo de la sesión para el clasificador y la señal correspondientes.

La pestaña *Global* incluye, para cada clasificador, la probabilidad de estrés combinada de todas las

señales (representando en trazo negro grueso la media entre señales) y un mapa de calor que muestra la evolución temporal de dicha media con una escala de color que va del azul (baja probabilidad de estrés) al rojo (alta probabilidad). Además, en una sección desplegable denominada *General plots* se presentan el intervalo RR derivado del ECG y la frecuencia respiratoria derivada de la señal RESP, ambos con sus umbrales de estrés personalizados basados en la respuesta fisiológica del propio sujeto.

Al finalizar el análisis, la aplicación ofrece la opción de exportar los resultados a un archivo CSV con nombre `Stress_Probability_YYYYMMDD_HHMMSS.csv`, que contiene la serie temporal completa de la probabilidad de estrés global para cada clasificador seleccionado.

5. Desarrollo

En este capítulo se explica cómo se implementó la aplicación, detallando las decisiones técnicas que se fueron tomando en cada etapa, los problemas que aparecieron por el camino y la forma en que se resolvieron. El desarrollo se llevó a cabo de manera iterativa e incremental: se partió de una exploración inicial de los datos y, poco a poco, se fue construyendo hasta llegar a un sistema funcional de detección de estrés.

5.1. Exploración inicial de los datos

La primera fase del desarrollo consistió en entender cómo estaban organizados por dentro los archivos del dataset y montar un flujo de trabajo básico para poder leerlos y procesarlos. El volumen de datos era tan grande que los archivos no se podían abrir directamente con herramientas habituales como Excel o un editor de texto, así que antes de poder trabajar con ellos hubo que desarrollar una serie de pequeñas utilidades para inspeccionarlos y convertirlos.

5.1.1. Inspección y verificación de archivos

El primer paso fue comprobar que los archivos contenían datos válidos y hacerse una idea de su tamaño, pero sin llegar a cargarlos enteros en memoria, ya que eran demasiado grandes. Para ello se creó la función `verificar_archivo`, que muestra el tamaño del archivo en bytes y sus primeras líneas.

Gracias a esta función se comprobó que cada señal del sistema Biopac tiene alrededor de 5 214 964 líneas por sujeto, que se corresponden con los registros tomados a 2000 Hz durante toda la sesión experimental. Este dato dejó claro que hacía falta aplicar técnicas de reducción de datos antes de intentar cualquier representación o análisis, y fue lo que motivó el diseño del *pipeline* de carga eficiente que se describe en el capítulo de metodología.

5.1.2. Conversión de formatos

Los archivos que exporta el sistema Biopac no siempre vienen con la extensión `.csv`; en algunos casos ni siquiera tienen una extensión estándar. Para poder tratarlos todos de la misma forma dentro del *pipeline*, se desarrolló la función `convertir_a_csv`, que recorre de forma recursiva la carpeta del dataset y le añade la extensión `.csv` a todos los archivos que no la tienen, copiando su contenido íntegro.

5.1.3. Reajuste de bases de datos.

Algunos archivos del dataset guardan varias señales en un mismo documento, con las columnas separadas por comas, lo que complica bastante su inspección en Excel. Para facilitar esta tarea se desarrollaron dos utilidades que se complementan entre sí. La primera, `separar_columnas_csv`, cambia los separadores de coma por punto y coma en un archivo CSV y genera una copia con el sufijo `_separado.csv`, que ya se puede abrir directamente en Excel con las columnas bien delimitadas. La segunda utilidad, `separar_columnas_dat`, está pensada para los archivos que guardan varias señales en distintas columnas dentro de un mismo fichero. Por cada archivo con el sufijo `_dat.csv` que encuentra en la carpeta del dataset, crea un archivo CSV independiente para cada columna y lo nombra a partir de la cabecera correspondiente.

Estas modificaciones, se realizan en la primera base de datos empleada, y una vez terminada la preparación de la primera base de datos, se pasó a adaptar la segunda, *Regulation of Brain Cognitive States through Auditory, Gustatory, and Olfactory Stimulation with Wearable Monitoring* [5]. A diferencia de la primera, esta base usa un formato de almacenamiento distinto, así que hubo que hacer un trabajo previo de adaptación para poder usarla en **BioVisor** sin tener que cambiar el funcionamiento general de la aplicación.

Con esta idea, se reorganizaron las señales siguiendo la misma estructura de carpetas que se había usado en la primera base de datos, de forma que las dos compartieran el mismo formato de entrada para las etapas posteriores de representación, procesamiento y extracción de características.

El primer paso fue identificar de forma automática el inicio y el final de las distintas sesiones del protocolo experimental. Para ello se utilizó el archivo `n_back_responses.csv`, que guarda la información temporal registrada durante el experimento. A partir de él se desarrolló el código encargado de localizar las distintas sesiones y de generar una tabla con sus tiempos de inicio, fin y duración. Todo esto se puede encontrar en el archivo `tiempo_sesiones.py`

La tabla generada permite conocer de forma automática los intervalos de tiempo que corresponden a cada una de las condiciones del experimento. Esta información hace falta para poder adaptar después las señales fisiológicas al formato que usa **BioVisor** y para quedarse únicamente con las fases del experimento que se van a utilizar en el análisis.

Una vez obtenidos estos tiempos, se procesan las señales registradas por la pulsera Empatica. En esta base de datos cada participante lleva un dispositivo en cada muñeca, así que las señales se guardan por separado en archivos del lado izquierdo (*Left*) y del lado derecho (*Right*). Para simplificar el procesamiento posterior, se decidió generar un único registro por cada señal fisiológica calculando la media entre los dos dispositivos.

Además de combinar las señales de ambas muñecas, el código elimina de forma automática la parte correspondiente a la última fase del experimento (*New Music Session*), ya que en este trabajo solo se emplean las sesiones de música relajante y música estresante.

Después de ejecutar los dos procedimientos, la segunda base de datos queda organizada con la misma estructura que la primera, lo que permite que **BioVisor** las procese a ambas de forma totalmente transparente. Así, la aplicación puede cargar, representar y analizar las señales fisiológicas de cualquiera de las dos bases sin tener que hacer ningún cambio adicional en el código, lo que facilita su uso y amplía las posibilidades de análisis.

5.2. Representación de señales

Una vez preparadas y organizadas las dos bases de datos, el siguiente paso fue conseguir representar las señales fisiológicas dentro de la aplicación.

Poder visualizar las señales es fundamental, ya que permite comprobar de un vistazo que los datos se han cargado correctamente, que su forma es coherente con lo que se espera de cada tipo de señal y que las distintas fases del protocolo experimental quedan correctamente situadas en el tiempo.

En esta sección se explica cómo **BioVisor** genera estas representaciones: la forma en que se organizan las gráficas de cada señal, cómo se construye un eje temporal común a todas ellas y de qué manera se muestran sobre las señales las fases del experimento. También se describen las herramientas de navegación que incorpora la aplicación (*zoom*, *desplazamiento* y *autoescalado*), pensadas para poder inspeccionar las señales con detalle antes de pasar a su análisis.

5.2.1. Representación inicial de señales

Una vez organizada la base de datos y separadas las señales fisiológicas en archivos independientes, el siguiente paso fue desarrollar una primera herramienta de visualización que permitiera comprobar que los datos se cargaban bien y que las señales tenían la forma que cabía esperar de cada una. El objetivo principal de esta fase era **asegurarse de que el proceso de lectura de los archivos funcionaba correctamente** antes de continuar con las etapas posteriores de procesamiento y análisis.

Para ello se desarrolló un primer programa en **Python** capaz de representar a la vez las seis señales fisiológicas que registra el sistema **Biopac** para un mismo sujeto: ECG, EDA, EMG, PPG, RESP y SKT. Todas se registran con una frecuencia de muestreo de 2000 Hz, así que el eje temporal de cada representación se obtiene a partir del número de muestras y de esa frecuencia.

La representación se organizó en una **única figura formada por seis subgráficas**, una por cada señal fisiológica, lo que permitió estudiar de forma conjunta cómo se comportaban todas durante el experimento.

La primera versión desarrollada, aunque servía para validar la carga de los datos, presentaba dos limitaciones importantes. Por un lado, **las rutas de los archivos de cada señal debían escribirse manualmente** en el código, de modo que analizar un sujeto distinto obligaba a modificar todas las rutas, lo que resultaba poco práctico y **dificultaba automatizar el proceso**. Por otro lado, dado que cada archivo contiene varios millones de muestras debido a la elevada frecuencia de muestreo (2000 Hz), la representación de las señales resultaba **lenta y costosa**.

Estas limitaciones motivaron el desarrollo de un **sistema de carga automática** de los archivos, que se describe en los apartados siguientes, así como la decisión de trabajar directamente con las señales a su frecuencia de muestreo original, evitando cualquier pérdida de información en las etapas posteriores del análisis.

5.2.2. Segmentación por sesión experimental

Para que las señales fisiológicas fueran más fáciles de interpretar, a la representación inicial se le añadió un sistema para marcar las distintas fases del protocolo experimental. La idea fue **poner**

sobre cada gráfica un sombreado de fondo que permite ver de un vistazo a qué periodo del experimento pertenece cada tramo de la señal. En concreto, se usó el color verde para la fase de música relajante, el rojo para la de música irritante y el azul para los periodos de relajación intermedios, dejando el fondo en blanco durante la fase inicial sin música.

La representación de las distintas fases del protocolo experimental se hace a partir de los tiempos de sesión que se obtuvieron durante la etapa de preprocesamiento, descrita en el apartado de Metodología. Para cada sujeto, la aplicación carga automáticamente el archivo **Session Times**, que se había generado antes a partir de los archivos de *triggers* y que contiene los instantes de inicio y fin de las fases de música relajante y música estresante. Con esta información se dibujan sobre las gráficas las zonas coloreadas que permiten identificar de un vistazo cada condición experimental y que, además, servirán después como referencia para el etiquetado automático de las ventanas de análisis.

Los instantes de inicio y fin de las distintas fases se obtuvieron a partir de los archivos **Triggers block.csv** que se incluyen en la carpeta **Biopac** de la Base de Datos 1. Estos archivos contienen las marcas temporales asociadas a cada una de las tareas que realizaban los participantes durante el experimento. Tras pasar los valores de número de muestra a segundos usando la frecuencia de muestreo del sistema **Biopac** (2000 Hz), se determinaron los tiempos de inicio y de fin de las fases de música relajante (**calming music**) y música estresante (**vexing music**) para cada uno de los cinco sujetos analizados. Los valores obtenidos se muestran en la Tabla 5.1.




Figura 5.1 Representación conjunta con código inicial del Sujeto 1 de la Base de datos 1.

Tabla 5.1 Tiempos de inicio y fin de las fases de música relajante y música estresante obtenidos a partir de los archivos `Triggers_block.csv` de la Base de Datos 1.

Sujeto	Inicio calmante (s)	Fin calmante (s)	Inicio estresante (s)	Fin estresante (s)
1 (3F)	502.35	1469.10	1612.88	2578.67
2 (4F)	1166.48	2126.62	2268.22	3233.22
3 (6M)	425.20	1373.90	1519.27	2461.19
4 (8F)	582.06	1504.74	1689.33	2641.78
5 (11F)	669.40	1638.24	1793.43	2760.99

5.3. Desarrollo de la interfaz gráfica

Una vez implementadas las funciones necesarias para cargar, preprocesar y analizar las señales fisiológicas, se pasó a desarrollar la interfaz gráfica de **BioVisor**. La idea principal de esta interfaz es ofrecer una herramienta con la que el usuario pueda llevar a cabo todas las etapas del procesamiento de forma intuitiva, sin tener que tocar el código fuente cada vez que quiere hacer un análisis nuevo.

Para ello, la aplicación se desarrolló con la biblioteca **CustomTkinter**, que permite crear interfaces gráficas modernas sobre **Tkinter** e integrar fácilmente las representaciones que se generan con **Matplotlib**. Así, desde un único entorno el usuario puede configurar la aplicación, elegir la base de datos, visualizar las señales fisiológicas y ejecutar los distintos algoritmos de análisis.

En los siguientes apartados se describe el desarrollo de cada uno de los módulos que forman la interfaz gráfica de **BioVisor**.

5.3.1. Arquitectura y organización del código

La aplicación se ha estructurado siguiendo una arquitectura modular que separa de forma estricta la lógica de procesamiento de la capa de presentación. Esta separación facilita el mantenimiento y la ampliación del código, permite reutilizar las funciones de análisis de forma independiente y hace posible modificar la apariencia de la aplicación sin alterar los algoritmos subyacentes, de modo que cada parte tiene una responsabilidad bien definida.

El proyecto se divide en dos grandes capas, representadas en la Figura 5.2. La capa de núcleo (**app/core**) contiene toda la lógica no gráfica, mientras que la capa de interfaz (**app/gui**) agrupa las ventanas con las que interactúa el usuario. De este modo, el procesamiento de las señales queda completamente aislado de su representación en pantalla.

Esta división lógica se refleja en la estructura física de directorios del proyecto, mostrada en la Figura 5.3.

El paquete **app/core** agrupa la lógica de procesamiento. El módulo **config.py** centraliza las constantes, los presets de frecuencia de cada dispositivo, las señales reconocidas y los colores de las fases. El módulo **data_loader.py** se encarga de localizar y leer los ficheros de señal de cada dispositivo. El módulo **filters.py** implementa el acondicionamiento y la eliminación de artefactos. El módulo **models.py** contiene la extracción de características, el cálculo de la variabilidad cardíaca, el etiquetado y los clasificadores. Por último, **plotter.py** genera las representaciones gráficas de las señales.




Figura 5.2 Arquitectura de la aplicación en dos capas: núcleo (lógica de procesamiento) e interfaz (ventanas de usuario).




Figura 5.3 Estructura modular del proyecto BioVisor.

El paquete `app/gui` agrupa las ventanas de la interfaz: `setup_window.py` (asistente de configuración), `app_window.py` (ventana principal y coordinación), `viewer_window.py` (visor de señales) y `analysis_window.py` (panel de análisis). El paquete `app/utils` reúne funciones auxiliares de apoyo, la carpeta `assets` contiene los recursos gráficos, la carpeta `datasets` alberga las bases de datos y el fichero `main.py` constituye el punto de entrada que instancia y lanza la ventana principal.

La comunicación entre módulos se resuelve mediante funciones de retorno (*callbacks*) y estructuras de datos compartidas. El asistente de configuración devuelve un diccionario con todos los parámetros de la sesión a través de una función de confirmación; la ventana principal utiliza ese diccionario para cargar los sujetos y transmite a los demás módulos las señales cargadas, sus frecuencias de muestreo y los intervalos de fase. Las señales se almacenan en un diccionario que asocia el nombre de cada señal con su vector de muestras, y las frecuencias de muestreo se guardan de forma análoga en un diccionario `fs_map`. Este diseño hace que el flujo de datos sea explícito y unidireccional: la configuración produce los datos, estos se procesan y, finalmente, los resultados se representan.

5.3.2. Ventana de configuración inicial

La primera ventana que aparece al ejecutar la aplicación es el asistente de configuración inicial. Se trata de una ventana modal que el usuario debe completar antes de poder acceder al resto de la aplicación, ya que en ella se establecen los parámetros básicos de la sesión. Desde ella se introducen todos los parámetros necesarios para el análisis: la carpeta que contiene la base de datos, el dispositivo de adquisición, el número de sujetos, las señales que se desean cargar y la frecuencia de muestreo asociada a cada una.




Figura 5.4 Proceso de configuración inicial de BioVisor. (a) Ventana emergente inicial mostrada al ejecutar la aplicación. (b) Selección de la carpeta que contiene la base de datos mediante el asistente de configuración.

La selección de la carpeta se realiza mediante un diálogo del sistema (`filedialog.askdirectory`), mientras que el dispositivo se elige entre *Biopac* y *Empatica* mediante botones de opción. La elección del dispositivo condiciona el resto del formulario: al cambiar de dispositivo se reconstruye dinámicamente la lista de señales y sus frecuencias por defecto, que se obtienen de las estructuras de configuración global. Estas estructuras centralizan los parámetros de cada dispositivo y evitan que aparezcan valores «mágicos» repartidos por el código.

Código 5.1 Presets de dispositivo definidos en `config.py`

```
1 # Frecuencias de muestreo por defecto de cada dispositivo (Hz)
2 DEVICE_FS = {
3     "Biopac": {"ECG": 2000, "EDA": 2000, "EMG": 2000,
4               "PPG": 2000, "RESP": 2000, "SKT": 2000},
5     "Empatica": {"BVP": 64, "EDA": 4, "TEMP": 4, "ACC": 32, "HR": 1},
6 }
7
8 # Senales reconocidas por dispositivo
9 DEVICE_SIGNALS = {
10    "Biopac": ["ECG", "EDA", "EMG", "PPG", "RESP", "SKT"],
11    "Empatica": ["BVP", "EDA", "TEMP", "ACC", "HR"],
12 }
```

Antes de cerrar la ventana, el método de confirmación valida todos los campos: comprueba que la

carpeta seleccionada existe, que el número de sujetos es un entero positivo, que se ha seleccionado al menos una señal y que todas las frecuencias introducidas son numéricas. Si alguna comprobación falla se muestra un mensaje de error y no se avanza. Cuando la validación es correcta, la configuración se empaqueta en un diccionario y se transmite a la ventana principal mediante la función de retorno.

5.3.3. Ventana principal

Una vez confirmada la configuración inicial, la aplicación abre automáticamente la ventana principal de BioVisor, implementada en la clase **AppWindow**. Esta ventana actúa como núcleo de la aplicación: coordina la carga de sujetos, la visualización y el análisis, y mantiene el estado de la sesión.

La interfaz se organiza mediante una rejilla (*grid*) con dos zonas principales. A la izquierda se sitúa una barra lateral que agrupa todos los controles: el botón para iniciar una nueva sesión, la casilla que activa o desactiva el filtrado de artefactos, la lista de sujetos generada automáticamente, los campos para introducir los intervalos de las fases experimentales, los botones para actualizar el visor y ejecutar el análisis, el botón de reinicio y una etiqueta de estado. A la derecha se dispone un contenedor de pestañas (**CTkTabview**) con dos vistas: el visor de señales y el panel de análisis.

La lista de sujetos se construye de forma automática a partir del número indicado en la configuración, generando un botón por cada sujeto. El botón de reinicio (*Reset App*) merece una mención especial: en lugar de cerrar la aplicación, devuelve la interfaz al estado inicial conservando la sesión configurada. Es decir, borra todas las señales, resultados y gráficas del sujeto anterior, restaura las frecuencias de muestreo originales y reconstruye la lista de sujetos, de modo que se puede cargar un nuevo sujeto sin volver a seleccionar la base de datos.

El filtrado de artefactos que se ofrece en la barra lateral se controla mediante la casilla *Apply artifact filter*. Cuando está activada, después de cargar las señales de un sujeto se aplica automáticamente el acondicionamiento definido en el módulo **filters.py** antes de representarlas. El objetivo de este acondicionamiento es eliminar las muestras espurias (saltos bruscos provocados por el movimiento, desconexiones momentáneas del sensor o valores fuera de rango físico) sin deformar la morfología de la señal, de modo que las etapas posteriores de visualización y análisis trabajen con datos más limpios.

El acondicionamiento se aplica señal a señal en dos etapas, implementadas en las funciones **mark artifacts** y **interpolate nans**. En la primera se marcan como no válidas (asignándoles el valor Not a Number (NaN)) las muestras consideradas artefacto; en la segunda, esos huecos se rellenan mediante interpolación lineal (**np.interp**) a partir de las muestras vecinas válidas, conservando así el número de muestras y el eje temporal originales de la señal.

La detección de artefactos combina dos criterios que operan sobre cada muestra. En primer lugar se aplica un límite físico inferior, definido en el diccionario **ABS_MIN**: se marca como artefacto toda muestra cuyo valor sea menor que dicho límite. En concreto, este límite es 0 para la actividad electrodérmica (EDA y Galvanic Skin Response (GSR), que no pueden ser negativas), 15 °C para la temperatura cutánea (SKT y TEMP, que no pueden situarse por debajo de ese valor) y 0 para la frecuencia cardíaca (HR); para el resto de señales no se define límite físico, por lo que este criterio no se les aplica.

En segundo lugar se aplica una detección de saltos de tipo relativo. Se calcula el valor absoluto de la diferencia entre cada muestra y la anterior y, sobre esas diferencias, se toma la mediana de las que son estrictamente mayores que cero (si todas fueran nulas se emplea el valor 1). Esa mediana, multiplicada por un factor característico de la señal (**JUMP_FACTOR**), fija el umbral de detección: toda diferencia que

supere el umbral se considera un salto anómalo y se marcan como artefacto tanto la muestra anterior como la posterior a dicho salto. Los factores empleados son 500 para las señales cardíacas rápidas (ECG, BVP y PPG), 200 para EMG, RESP y ACC, 50 para EDA y GSR, 30 para HR, 20 para SKT y TEMP, y 200 por defecto para cualquier señal no incluida en la tabla. Cuanto mayor es el factor, más permisivo resulta el criterio: por eso las señales con transitorios rápidos pero legítimos (como los picos RR del ECG o el pulso del BVP) usan un factor de 500, mientras que las señales lentas como la temperatura cutánea usan 20, de forma que en ellas un cambio abrupto se detecta de inmediato como artefacto. Como el umbral se calcula a partir de la mediana de los incrementos de la propia señal, el criterio es relativo y, por tanto, independiente de las unidades en que esté expresada (mV, μ V, V, etc.) y del rango de cada modalidad.


La primera etapa se implementa en la función `_mark_artifacts`, que devuelve la señal con las muestras defectuosas marcadas como NaN y el número de artefactos detectados. Como un salto brusco afecta tanto a la muestra anterior como a la posterior, ambas se marcan para su posterior corrección.

La segunda etapa, `_interpolate_nans`, sustituye los huecos marcados por interpolación lineal empleando únicamente las muestras válidas. Ambas etapas se encadenan en la función `clean_signal`, que además devuelve un pequeño informe con el número y el porcentaje de artefactos corregidos, útil para valorar la calidad del registro.


Finalmente, la función `clean_all` recorre todas las señales cargadas y les aplica `clean_signal`, devolviendo el conjunto acondicionado junto con los informes de cada señal. Esta es la función que invoca el cargador de datos cuando la casilla de filtrado está activada.

Código 5.2 Aplicación del filtrado a todas las senales (`filters.py`)

```
def clean_all(signals, fs_map):
    cleaned, reports = {}, {}
    for sig, arr in signals.items():
        cleaned[sig], reports[sig] = clean_signal(arr, sig, fs_map.get(sig, 2000))
    return cleaned, reports
```



(a)



(b)

Figura 5.5 Carga de un sujeto en la aplicación BioVisor. (a) Representación inicial de las señales fisiológicas correspondientes al sujeto seleccionado. (b) Visualización de las señales tras la detección de artefactos durante el proceso de análisis.

5.3.4. Carga automática de sujetos

Al pulsar el botón de un sujeto, la aplicación localiza y carga automáticamente sus señales (Figura 5.5a). La búsqueda se basa en una convención de nombres: a partir de la carpeta raíz de la base de datos se construye la ruta del sujeto (`{base}_Sujeto{num}`) y se comprueban las subcarpetas propias de cada dispositivo (`Biopac_data` o `Empatica_data`). En el caso de `Empatica` se apunta directamente a su subcarpeta para que los ficheros combinados del sujeto no queden ocultos por otros ficheros crudos.

El proceso de carga se delega en la función `load_subject_folder`, que recorre los ficheros CSV de la carpeta y de un nivel de subcarpetas, identifica el tipo de señal a partir del nombre del fichero y delega la lectura en la función específica de cada dispositivo. La lectura de los ficheros de `Biopac` es tolerante al formato: prueba distintos separadores y selecciona la columna con mayor varianza, que corresponde a la señal registrada.

En el caso de `Empatica`, cada señal se conserva a su frecuencia de muestreo nativa (BVP a 64 Hz, EDA y TEMP a 4 Hz, ACC a 32 Hz y HR a 1 Hz). Esta decisión es relevante: al no remuestrear las señales lentas a una frecuencia común elevada se evita generar millones de muestras interpoladas que no aportan información y que degradarían las características extraídas posteriormente. La frecuencia de cada señal se toma de la configuración del asistente y, en el caso del acelerómetro, se calcula la magnitud del vector de aceleración a partir de sus tres ejes.

La carga se realiza mostrando una ventana emergente con un registro de progreso, de forma que el usuario puede seguir en tiempo real qué señales se cargan y detectar posibles incidencias. Si no se encuentra ningún fichero válido, se informa mediante un cuadro de diálogo y no se modifica el estado de la aplicación.

Antes de representar las señales, si el usuario ha mantenido activado el filtrado, se aplica el acondicionamiento definido en `filters.py`. Este módulo elimina los artefactos mediante una detección de saltos relativa: se marca como artefacto toda muestra cuyo cambio respecto a la anterior supere un umbral proporcional a la mediana de los incrementos de la señal. Al ser un criterio relativo, funciona con independencia de las unidades en que esté expresada la señal. Adicionalmente se aplican límites físicos (por ejemplo, la conductancia de la piel no puede ser negativa y la temperatura cutánea no puede estar por debajo de un valor mínimo). Las muestras marcadas se sustituyen por interpolación lineal.

5.3.5. Representación de las señales fisiológicas

Una vez cargados y acondicionados los datos, la aplicación genera de forma automática la representación de todas las señales disponibles. El visor, implementado en la clase `ViewerWindow`, integra una figura de `Matplotlib` dentro de la interfaz mediante `FigureCanvasTkAgg`, lo que permite mostrar las gráficas y, a la vez, contar con las herramientas interactivas de la biblioteca.

Cada señal se dibuja en su propio panel, y los paneles se apilan uno encima de otro. Todos comparten el mismo eje temporal (`sharex`), de manera que el zoom y el desplazamiento se sincronizan entre señales y resulta muy fácil comparar cosas que ocurren a la vez en distintas modalidades. El eje de tiempo de cada señal se construye a partir de su número de muestras y de su frecuencia de muestreo, lo que asegura que todas queden bien alineadas en el tiempo aunque tengan frecuencias distintas.

Un detalle importante de la visualización es el escalado vertical automático. En vez de fijar unos límites verticales estáticos, la aplicación reajusta los límites de cada panel al mínimo y al máximo de

la parte de la señal que se está viendo, de modo que el trazo ocupa siempre toda la altura del panel. Este ajuste se vuelve a calcular cada vez que el usuario amplía o desplaza la vista.




Figura 5.6 Representación de señales base en la aplicación BioVisor.

5.3.6. Representación de las fases experimentales

Con el fin de facilitar la interpretación de las señales, la aplicación representa las fases del protocolo experimental mediante zonas coloreadas superpuestas a las gráficas (Figura 5.6). El protocolo distingue entre periodos de música relajante (*calming*), periodos de estímulo estresante (*vexing*) y periodos de relajación o sin música (*relax*), a los que se asigna un color característico definido en la configuración global.

Los tiempos de inicio y fin de cada fase se obtienen del fichero de tiempos de sesión (*session_times*), un CSV separado por punto y coma que contiene las columnas de inicio y fin de las fases de *calming* y *vexing*. Estos tiempos se leen directamente del fichero y se vuelcan en los campos de la interfaz. Los periodos de relajación no se especifican explícitamente, sino que se calculan como el complemento temporal de las fases anteriores: todo el tiempo que queda fuera de los intervalos de *calming* y *vexing* se considera reposo.

Código 5.3 Colores de fase y calculo del periodo de relajacion

```
1 PHASE_COLORS = { # config.py
2     "calming": ("#2cec69", "Calming music"),
3     "relax": ("#AE1285", "Relax"),
4     "vexing": ("#e3f632", "Vexing / Stress"),
5 }
6
7 def _read_phase_intervals(self):
8     calming, vexing = [], []
9     # ... se leen los pares (inicio, fin) de calming y vexing ...
10    relax, cursor = [], 0.0
11    sig_dur = max(len(sig) / fs_map.get(name, 2000)
12                  for name, sig in self._signals.items())
13    for start, end in sorted(calming + vexing, key=lambda x: x[0]):
14        if start > cursor:
```

```

15     relax.append((cursor, start)) # hueco entre fases = relax
16     cursor = max(cursor, end)
17     if cursor < sig_dur:
18         relax.append((cursor, sig_dur)) # tramo final = relax
19     return {"calming": calming, "vexing": vexing, "relax": relax}

```

Cada intervalo se dibuja sobre las gráficas mediante regiones sombreadas (`axvspan`), y se genera automáticamente una leyenda que asocia cada color con su fase correspondiente.

5.3.7. Herramientas de navegación

La interfaz incorpora las herramientas de navegación estándar de `Matplotlib` a través de la barra `NavigationToolbar2Tk`, que permite ampliar una región de interés, desplazarse por la señal y restaurar la vista inicial. Estas herramientas se complementan con dos comportamientos propios de `BioVisor`.

En primer lugar, gracias a que todos los paneles comparten el eje temporal, cualquier operación de zoom o desplazamiento se propaga simultáneamente a todas las señales, lo que mantiene la sincronización temporal y facilita el análisis conjunto. En segundo lugar, el escalado vertical automático descrito anteriormente se conecta a los eventos de cambio del eje horizontal, de modo que al modificar la ventana temporal se recalculan los límites verticales de cada panel para aprovechar toda la altura disponible.




Figura 5.7 Ejemplos de zoom sobre señales fisiológicas en BioVisor. (a) Ampliación mediante la herramienta de zoom sobre la fase de música relajante, permitiendo observar con mayor detalle la evolución de las señales. (b) Visualización del límite temporal entre el periodo de relajación y el inicio de la fase de música estresante, donde puede apreciarse el cambio de condición experimental.

5.3.8. Panel de análisis

Además de la visualización, `BioVisor` incorpora un panel dedicado al análisis automático de las señales, implementado en la clase `AnalysisWindow`. Este panel se divide en dos zonas: a la izquierda, un conjunto de controles que permiten seleccionar las señales que se analizarán, los algoritmos de clasificación, los tipos de gráfica y los parámetros de la ventana de análisis (tamaño y desplazamiento) y a la derecha, una zona de resultados organizada en pestañas, con una pestaña por cada señal y una pestaña global que combina la información de todas ellas.

El proceso completo se lanza con un único botón y consta de tres etapas encadenadas: la extracción de

características de cada señal, el entrenamiento del modelo seleccionado con las etiquetas del protocolo y la representación de los resultados. A continuación se describe cada una de estas etapas.

Selección del algoritmo

La aplicación permite elegir entre cuatro algoritmos de aprendizaje automático: RF, LightGBM, SVM y KNN. La disponibilidad de cada algoritmo se comprueba en tiempo de ejecución, de forma que si una biblioteca no está instalada el algoritmo correspondiente no aparece como opción. Cada modelo se configura con parámetros orientados a conjuntos de datos pequeños y desbalanceados; en particular, se emplea el ponderado de clases (*class weight balanced*) en los modelos que lo permiten, para compensar el hecho de que las ventanas de estrés suelen ser minoría frente a las de reposo.

Código 5.4 Construcción de los clasificadores disponibles

```
def _build_classifier(name):
    if name == "Random Forest":
        return RandomForestClassifier(n_estimators=200, max_depth=None,
                                     class_weight="balanced",
                                     random_state=42, n_jobs=-1)
    if name == "LightGBM":
        return LGBMClassifier(n_estimators=200, random_state=42,
                              class_weight="balanced", verbose=-1, n_jobs=-1)
    if name == "SVM":
        return SVC(kernel="rbf", probability=True, class_weight="balanced",
                  random_state=42, C=1.0, gamma="scale")
    if name == "KNN":
        return KNeighborsClassifier(n_neighbors=5, weights="distance", n_jobs=-1)
```




Figura 5.8 Ventana de configuración del análisis en BioVisor, desde la que el usuario puede seleccionar el modelo de aprendizaje automático, las señales fisiológicas que se emplearán durante el análisis y los parámetros necesarios para ejecutar la estimación del nivel de estrés.

Extracción automática de características

Para poder aplicar los algoritmos de clasificación, cada señal se transforma en un conjunto de características calculadas sobre ventanas temporales solapadas. El tamaño de la ventana y el desplazamiento

entre ventanas son configurables desde la interfaz; por defecto se emplean ventanas de un minuto con un solapamiento del 50 %. Por cada ventana se obtiene un vector de doce características: ocho de carácter general (media, desviación típica, valor eficaz, amplitud pico a pico, asimetría, curtosis y la proporción de energía en las bandas baja y alta del espectro) y cuatro específicas de cada tipo de señal.

Las cuatro características específicas se adaptan a lo que mide realmente cada señal. Las señales cardíacas (ECG y PPG en **Biopac**, BVP en **Empatica**) aportan variabilidad de la frecuencia cardíaca; la señal de frecuencia cardíaca de **Empatica** (HR) aporta su valor medio y su tendencia; la actividad electrodérmica aporta el nivel de conductancia y las respuestas de conductancia; la respiración aporta la frecuencia respiratoria; y la temperatura cutánea aporta su valor medio y su deriva. Esta especialización es clave: aplicar las mismas características a señales de naturaleza distinta produciría descriptores poco informativos y empeoraría la clasificación.

Código 5.5 Vector de características por ventana (fragmento de `_window_features`)

```
1 base = np.array([
2     mean, std,
3     np.sqrt(np.mean(seg**2)), # valor eficaz (RMS)
4     np.ptp(seg), # amplitud pico a pico
5     float(np.mean(((seg - mean)/std)**3)), # asimetria
6     float(np.mean(((seg - mean)/std)**4)), # curtosis
7     fft[:len(fft)//4].sum() / tp, # energia banda baja
8     fft[len(fft)//4:].sum() / tp, # energia banda alta
9 ], dtype=float)
10
11 extra = np.zeros(4) # 4 características específicas
12 if sig_type in ("ECG", "PPG"):
13     extra = _hrv_features(seg, fs)[[3, 2, 7, 4]] # BPM, RMSSD, LF/HF, pNN50
14 elif sig_type == "BVP":
15     extra = _bvp_features(seg, fs) # HRV adaptada a la onda de pulso
16 elif sig_type == "HR":
17     extra = _hr_features(seg, fs) # HR media, variabilidad, tendencia
18 # ... EDA, EMG, RESP, SKT, TEMP, ACC ...
19 features = np.concatenate([base, extra]) # 12 características en total
```

La extracción de características se apoya en el filtrado digital de las señales. Para detectar los latidos en las señales cardíacas se aplica un filtro de **Butterworth** paso banda; en el caso del ECG se emplea la banda de 0,5 a 40 Hz, apropiada para el Complejo QRS (despolarización ventricular) (QRS), mientras que para la onda de pulso BVP se utiliza una banda más estrecha (0,5 a 8 Hz), acorde con su naturaleza más suave. Sobre la señal filtrada se localizan los picos y, a partir de la distancia entre ellos, se calculan los intervalos entre latidos y los descriptores de variabilidad cardíaca.

Código 5.6 Filtro de Butterworth paso banda empleado en la detección de picos

```
1 def _bandpass(signal, fs, low=0.5, high=40.0):
2     nyq = fs / 2.0
3     low_n = max(low / nyq, 1e-4)
4     high_n = min(high / nyq, 0.9999)
5     if low_n >= high_n:
6         return signal.copy()
7     b, a = butter(4, [low_n, high_n], btype="band") # orden 4
8     return filtfilt(b, a, signal) # filtrado sin desfase
```

En el caso de la señal de respiración (RESP), la frecuencia respiratoria no se obtiene por detección

de picos, sino contando los cruces por cero de la señal. En primer lugar se filtra la ventana con un paso banda de **Butterworth** entre 0,05 y 2 Hz, que corresponde al rango de frecuencias de la respiración humana y elimina tanto la deriva de la línea base como el ruido de alta frecuencia. A continuación se localizan los cruces por cero detectando los cambios de signo de la señal filtrada mediante `np.diff(np.sign(filt))`, que devuelve las posiciones donde la señal pasa de positiva a negativa o viceversa. Dado que cada ciclo respiratorio completo produce dos cruces por cero (uno ascendente y otro descendente), el número de ciclos contenidos en la ventana es igual a la mitad del número de cruces detectados. Dividiendo ese número de ciclos entre la duración de la ventana en segundos (`len(seg)/fs`) y multiplicando por 60 se obtiene la frecuencia respiratoria expresada en respiraciones por minuto.

Junto con la frecuencia respiratoria se calculan otras dos características de esta señal: la amplitud, como el valor pico a pico de la señal filtrada (`np.ptp`), que indica la profundidad de la respiración, y la irregularidad del ritmo respiratorio, como la desviación típica de las distancias entre cruces consecutivos (`np.std(np.diff(crosses))`), que es tanto mayor cuanto más variable e inestable es la respiración dentro de la ventana. Si se detectan dos cruces o menos, la irregularidad se fija en cero por no haber información suficiente.

Código 5.7 Extracción de la frecuencia respiratoria a partir de los cruces por cero (rama RESP de `_window_features`)

```

1 elif sig_type == "RESP":
2     filt = _bandpass(seg, fs, 0.05, 2.0) # banda de respiracion 0.05-2 Hz
3     crosses = np.where(np.diff(np.sign(filt)))[0] # posiciones de cruce por cero
4     extra[:3] = [
5         (len(crosses) / 2) / (len(seg) / fs) * 60, # frecuencia respiratoria (brpm)
6         np.ptp(filt), # amplitud (pico a pico)
7         np.std(np.diff(crosses)) if len(crosses) > 2 else 0.0, # irregularidad
8     ]

```

Entrenamiento y predicción

El entrenamiento se realiza de forma **supervisada** empleando exclusivamente las **etiquetas del protocolo experimental**. Cada ventana temporal se etiqueta según la fase en la que se encuentra su centro: las ventanas cuyo centro cae dentro de un periodo de *calming* o de reposo se etiquetan como **ausencia de estrés**, y las que caen dentro de un periodo de *vexing* como **presencia de estrés**. Las ventanas que quedan fuera de cualquier intervalo del protocolo (por ejemplo, el tiempo que el dispositivo sigue registrando más allá de la sesión) se descartan tanto del entrenamiento como de la evaluación, lo que evita introducir un fuerte desbalance de clases. De este modo, la variable objetivo con la que se entrena el clasificador procede **únicamente de la referencia temporal del experimento**, y no de las propias características extraídas de la señal.

Conviene subrayar este punto para evitar cualquier ambigüedad. La votación ponderada entre señales descrita en el apartado **4.4.4 Etiquetado fisiológico por votación ponderada no interviene en ningún momento en el entrenamiento**: se trata de un *apoyo estrictamente visual* pensado para mostrar el nivel de activación fisiológica combinada a lo largo de la sesión (el mapa de calor y la envolvente de la pestaña global). No se emplea para etiquetar las ventanas, no alimenta el ajuste del modelo y **no interviene en el cálculo del AUC**. Mantener separada esa representación de las etiquetas de entrenamiento es lo que evita que el sistema caiga en un esquema circular, en el que el modelo aprendería a reproducir un umbral calculado a partir de las mismas características que recibe como entrada.

El clasificador se integra en una tubería (*pipeline*) que primero imputa los valores ausentes con la mediana y después estandariza las características, garantizando así que todas las variables tengan la misma escala antes de entrar al modelo. Con el modelo ajustado sobre las ventanas etiquetadas según el protocolo se estima la probabilidad de estrés en todo el registro, lo que permite representar la evolución temporal del estrés a lo largo de la sesión.

Para evaluar el rendimiento de forma honesta y aprovechar al máximo un conjunto de datos reducido, la curva ROC no se calcula sobre los datos de entrenamiento, sino a partir de predicciones obtenidas por **validación cruzada estratificada**. De esta forma cada ventana se evalúa con un modelo que no la ha visto durante su entrenamiento, obteniéndose un AUC representativo. Es importante insistir en que la referencia frente a la que se mide ese AUC son **las mismas etiquetas del protocolo** empleadas en el entrenamiento, de modo que el rendimiento reportado refleja la capacidad real del modelo para discriminar las fases *veering* de las de *calming* y reposo, y no su capacidad para reproducir la votación ponderada. Cuando no se dispone de intervalos de protocolo, la aplicación recurre como alternativa a unas etiquetas fisiológicas aproximadas, advirtiendo en ese caso de que la curva ROC es solo orientativa.

Código 5.8 Tubería de clasificación y evaluación por validación cruzada

```
def _make_pipeline(clf_name):
    return Pipeline([
        ("imp", SimpleImputer(strategy="median")),
        ("scl", StandardScaler()),
        ("clf", _build_classifier(clf_name)),
    ])

def _oof_scores(clf_name, X, y):
    # Probabilidad de estrés out-of-fold (sin fuga de datos)
    n_min = int(np.bincount(y).min())
    if len(np.unique(y)) < 2 or n_min < 2:
        return None
    skf = StratifiedKFold(n_splits=min(5, n_min), shuffle=True, random_state=42)
    proba = cross_val_predict(_make_pipeline(clf_name), X, y,
                             cv=skf, method="predict_proba")
    return proba[:, 1]
```

Representación de resultados

Tras ejecutar el análisis, los resultados se presentan de forma organizada en la interfaz. En la pestaña de cada señal aparece una cabecera con el número de ventanas clasificadas como estrés, la probabilidad media y el valor de AUC obtenido, seguida de las gráficas seleccionadas: la distribución de las características por fase mediante diagramas de caja (*boxplots*), la curva ROC del clasificador y la evolución temporal de la probabilidad de estrés, sobre la que se marcan las ventanas que el modelo ha predicho como estresantes.

La pestaña global combina la información de todas las señales. Por un lado, superpone la probabilidad de estrés de cada señal, cada una con un color distinto, y añade en negro la **media** de todas ellas, lo que ofrece una visión de conjunto de la sesión. Como cada señal tiene su propia frecuencia de muestreo y, por tanto, un número distinto de ventanas, las probabilidades se **interpolan sobre un eje temporal común** antes de promediarse. Sobre esta gráfica se sombrean además los intervalos de *calming* (en verde) y de estrés (en rojo), de modo que se puede contrastar de un vistazo la predicción del modelo con las fases reales del protocolo.

Por otro lado, la pestaña global incluye un **mapa de calor** de la envolvente de la probabilidad media. Para obtenerlo, se calcula primero la envolvente de la probabilidad media como el módulo de la señal analítica obtenida mediante la *transformada de Hilbert*; a continuación, esa envolvente se suaviza con un filtro de *Savitzky-Golay* y se normaliza al rango $[0, 1]$, y finalmente se representa como una franja de color que va del azul (activación baja) al rojo (activación alta). Esta representación permite identificar de un vistazo los tramos de mayor activación a lo largo de la sesión.


Además, en la sección de gráficas generales se incluyen representaciones derivadas de señales concretas, como el intervalo RR calculado a partir del ECG o la frecuencia respiratoria obtenida de la señal de respiración, que resultan útiles para interpretar fisiológicamente los resultados. En la evolución temporal de la probabilidad de estrés de cada señal, por su parte, se traza una línea horizontal en el **umbral de decisión** 0,5, se somborean los intervalos de estrés reales del protocolo y se marcan las ventanas clasificadas como estresantes, lo que facilita comparar la salida del modelo con la referencia experimental.


Todas estas figuras se generan con `Matplotlib` y se integran en las pestañas de la interfaz mediante `FigureCanvasTkAgg`. Por brevedad no se incluye aquí el código de las funciones de representación (`_plot_stress_timeline`, `_plot_global_stress_probability`, `_plot_global_heatmap_mean`, `_plot_boxplots_big` y `plot_roc`); todas ellas pueden consultarse en el repositorio público del proyecto (véase el apartado **5.3.10 Disponibilidad del código fuente y documentación**).

5.3.9. Exportación de resultados

La aplicación permite exportar los resultados del análisis para su uso posterior. En concreto, exporta la serie temporal de la probabilidad de estrés global de cada clasificador, entendida como la media de la probabilidad de todas las señales en cada instante. Para ello, las probabilidades de las distintas señales se interpolan sobre una rejilla temporal común y se promedian, generándose un fichero CSV con una columna de tiempo y una columna por cada modelo analizado.

El nombre del fichero se genera automáticamente incorporando la fecha y la hora, lo que evita sobrescribir exportaciones anteriores y facilita la trazabilidad de los resultados. La operación se realiza mediante un diálogo de guardado del sistema, de modo que el usuario elige la ubicación del fichero (Figura 5.9).





time_s	Random Forest_global_mean_score	LightGBM_global_mean_score	SVM_global_mean_score	KNN_global_mean_score
30.0000	0.053333	0.086008	0.189813	0.166667
60.0000	0.061667	0.054371	0.198325	0.100000
90.0000	0.071667	0.109221	0.197108	0.166667
120.0000	0.103333	0.118810	0.190882	0.133333
150.0000	0.070000	0.516213	0.240895	0.300000
180.0000	0.048333	0.085804	0.190454	0.166667
210.0000	0.053333	0.091647	0.187359	0.100000
240.0000	0.045000	0.064852	0.197417	0.133333
270.0000	0.036667	0.081753	0.199338	0.166667
300.0000	0.018333	0.061656	0.185850	0.033333
330.0000	0.016667	0.068077	0.190643	0.100000
360.0000	0.048333	0.053884	0.192258	0.100000
390.0000	0.036667	0.038994	0.183730	0.100000
420.0000	0.088333	0.083400	0.215695	0.266667
450.0000	0.064333	0.481605	0.262829	0.366667
480.0000	0.066667	0.066821	0.179065	0.166667
510.0000	0.133333	0.084800	0.203029	0.200000
540.0000	0.080000	0.612727	0.326692	0.500000
570.0000	0.088333	0.155445	0.212169	0.200000
600.0000	0.066667	0.032793	0.192284	0.100000
630.0000	0.030000	0.040381	0.185528	0.066667
660.0000	0.041667	0.048904	0.172226	0.033333
690.0000	0.038333	0.066091	0.200850	0.066667
720.0000	0.051667	0.050643	0.187160	0.033333
750.0000	0.035000	0.077367	0.189705	0.000000
780.0000	0.040000	0.057511	0.188295	0.066667

(c)

Figura 5.9 Proceso de exportación de la probabilidad de estrés en formato CSV. (a) Selección del archivo CSV que se desea exportar desde la aplicación. (b) Mensaje mostrado tras completar la exportación del archivo. (c) Contenido del archivo CSV generado con los valores de probabilidad de estrés obtenidos durante el análisis.

5.3.9.1. LOSO

Hasta este punto, el rendimiento de los modelos se había evaluado mediante **validación cruzada** sobre las ventanas de un mismo sujeto. Sin embargo, esa forma de evaluar tiene una limitación importante: como las ventanas de entrenamiento y de prueba proceden de la misma persona, el modelo puede estar aprovechando **rasgos propios de ese individuo** en lugar de patrones de estrés realmente generalizables. Para comprobar hasta qué punto el sistema funciona con **personas que no ha visto nunca**, se añadió una segunda validación mediante la estrategia LOSO.

La idea es sencilla: se recorren todos los sujetos de la base de datos y, en cada iteración, se **aparta uno de ellos como conjunto de prueba** mientras que el resto se emplea para entrenar el clasificador. Una vez entrenado, el modelo estima la probabilidad de estrés sobre las ventanas del sujeto que se había dejado fuera, es decir, sobre datos completamente nuevos para él, y el proceso se repite hasta que cada participante ha actuado una única vez como conjunto de evaluación. La diferencia clave respecto a la validación anterior es que **todas las ventanas de un mismo sujeto permanecen siempre juntas** en el mismo conjunto, y nunca se reparten entre entrenamiento y prueba.

Esta evaluación se implementó mediante un **script independiente** de la aplicación principal, ya que **BioVisor** está pensado para trabajar con *un sujeto cada vez*, mientras que LOSO necesita disponer de todos los sujetos a la vez. El script reutiliza directamente las funciones del módulo `models.py` encargadas de la extracción de características y del etiquetado automático, de modo que la evaluación emplea **exactamente las mismas características y el mismo criterio de etiquetado** que la aplicación, y conserva todas sus etapas de procesamiento (imputación de valores ausentes con la mediana y estandarización antes de entrenar). Como clasificador se empleó un *Random Forest* integrado

en una tubería idéntica a la de la aplicación, para que los resultados fueran comparables con los del resto del capítulo.

Como métrica se utilizó el área bajo la curva ROC (AUC), calculada a partir de las probabilidades predichas para el sujeto excluido en cada iteración. Al completar todas las iteraciones, las predicciones de todos los sujetos se **combinan** para obtener un único valor de AUC por señal, y el script genera automáticamente una tabla resumen con estos resultados, que se analizan en el capítulo de resultados. Se trata, por tanto, de una prueba **bastante más exigente** que la validación cruzada convencional, ya que obliga al modelo a reconocer patrones **comunes a distintas personas**.

El script completo de esta validación puede consultarse en el repositorio público del proyecto, explicado en el siguiente apartado, en específico, en el archivo `loso eval.py`.

5.3.10. Disponibilidad del código fuente y documentación

El código fuente completo de **BioVisor** se ha publicado en un repositorio público de GitHub, accesible en la dirección <https://github.com/raquelgomez2003/Trabajo-de-Fin-de-Grado/tree/main/BioVisor>, con el fin de garantizar la reproducibilidad del trabajo y permitir su consulta, uso y posterior ampliación. El repositorio contiene la totalidad de los módulos descritos en este capítulo, organizados según la estructura modular presentada, junto con las instrucciones necesarias para su instalación y ejecución.

Para facilitar el manejo de la aplicación a cualquier usuario, se adjunta además un manual de usuario que describe paso a paso su funcionamiento y que se incluye como anexo en este documento (véase el Anexo A).

6. Resultados

6.1. Conjuntos de datos y configuración del análisis

En este apartado se describen los dos conjuntos de datos empleados y la configuración común con la que se han obtenido todos los resultados. Cada dispositivo se ha evaluado sobre una base de datos distinta —la *Base de datos 1* para las señales de **Biopac** y la *Base de datos 2* para las de **Empatica**, por lo que los resultados de ambos dispositivos no corresponden a los mismos sujetos y no constituyen una comparación pareada, sino la evaluación de cada dispositivo dentro de su propia base.

La *Base de datos 1* recoge las señales adquiridas mediante el equipo **Biopac** en cinco sujetos. De este dispositivo se emplean seis señales fisiológicas (ECG, EDA, EMG, PPG, RESP y SKT), todas ellas registradas a una frecuencia de muestreo de 2000 Hz. La *Base de datos 2* contiene las señales adquiridas con la pulsera de muñeca **Empatica E4** en diez sujetos, de la que se utilizan cinco señales (BVP, EDA, TEMP, ACC y HR), cada una a su frecuencia de muestreo nativa (64, 4, 4, 32 y 1 Hz, respectivamente). En ambos casos, el protocolo experimental se estructura en tres fases: un periodo de música relajante, un periodo de estímulo irritante y periodos de reposo, que constituyen la referencia utilizada para el etiquetado de las ventanas.

En cuanto a la configuración común del análisis, todas las señales se procesan mediante ventanas temporales solapadas de las que se extrae un vector de características, y sobre ellas se entrenan y evalúan los cuatro algoritmos de aprendizaje automático considerados: RF, LightGBM, SVM y KNN. Por defecto se emplean ventanas de 60 segundos con un desplazamiento de 30 segundos, lo que supone un solapamiento del 50 %. El rendimiento de cada modelo se cuantifica mediante el área bajo la curva ROC (AUC), estimada mediante validación cruzada por **bloques temporales**. Dado que las ventanas presentan un solapamiento del 50 %, dos ventanas contiguas comparten la mitad de su contenido; para evitar la fuga de información, las ventanas se agrupan en bloques temporales contiguos que se reparten de forma conjunta entre entrenamiento y validación mediante **GroupKFold**, y adicionalmente se *purgan* del conjunto de entrenamiento las ventanas que solapan temporalmente con las de validación. De este modo se garantiza que cada ventana se evalúa con un modelo que no ha empleado durante su entrenamiento ninguna ventana solapada con ella. La Tabla 6.1 resume las características principales de ambas bases de datos.

6.2. Validación de la representación de las señales

Antes de analizar los resultados obtenidos mediante los modelos de aprendizaje automático, fue necesario comprobar que la aplicación cargaba y representaba correctamente las señales fisiológicas de las dos bases de datos empleadas. Para ello, las representaciones generadas por **BioVisor** se compararon con las publicadas en los artículos de referencia de cada base de datos, verificando que la morfología de las señales, la escala temporal y la distribución de las diferentes fases del protocolo experimental coincidían con las descritas por sus autores.


Tabla 6.1 Resumen de las dos bases de datos empleadas.

Característica	Base de datos 1	Base de datos 2
Dispositivo	Biopac	Empatica E4 (pulsera de muñeca)
Señales (frecuencia de muestreo)	ECG, EDA, EMG, PPG, RESP y SKT (todas a 2000 Hz)	BVP (64 Hz), EDA (4 Hz), TEMP (4 Hz), ACC (32 Hz) y HR (1 Hz)
Número de sujetos	5	10
Fases del protocolo	Música relajante, estímulo irritante y reposo	Música relajante, estímulo irritante y reposo


Esta validación permitió confirmar que el proceso de carga, sincronización y representación de las señales se realizaba correctamente, garantizando que los análisis posteriores se llevaran a cabo sobre datos correctamente procesados y representados.

6.2.1. Base de datos 1: señales Biopac


Como primera comprobación, se representan las señales fisiológicas originales registradas por el sistema Biopac para los cinco sujetos incluidos en la Base de Datos 1. Estas representaciones permiten verificar que las señales se han cargado correctamente y que las distintas fases del protocolo experimental se corresponden con los intervalos temporales obtenidos durante el preprocesamiento. La Figura 6.1 muestra las señales completas de cada sujeto, incluyendo la delimitación de los periodos sin música, música relajante, relajación y música estresante.




(a) Sujeto 1




(b) Sujeto 2



(c) Sujeto 3



(d) Sujeto 4




(e) Sujeto 5

Figura 6.1 Representación de las señales fisiológicas originales correspondientes a los cinco sujetos de la Base de Datos 1 para el dispositivo **Biopac**.


Cabe señalar que, en esta base de datos, no se dispone de una representación en el artículo de referencia con la que contrastar estas señales, ya que no aparecen representadas de forma específica; por ello, la validación se basa únicamente en la correcta carga, morfología y delimitación temporal de las fases observadas en BioVisor.

6.2.2. Base de datos 2: señales Empatica

Tras validar la representación de la Base de Datos 1, se realizó el mismo procedimiento con la Base de Datos 2, adquirida mediante dispositivos Empatica. El artículo de referencia de esta base incluye la representación de un sujeto, indicando sus dos experimentos diferentes (el relacionado con la música y el relacionado con el gusto y olfato). El sujeto representado en este caso, es el guardado como el noveno sujeto. Por ese motivo, la comparación directa con el artículo se realiza únicamente con el sujeto 9, cuya representación en BioVisor se muestra junto a la publicada en el artículo [2] en la Figura 6.2.



(a) Sujeto 9 — artículo de referencia



(b) Sujeto 9 — BioVisor


Figura 6.2 Comparación entre las señales del sujeto 9 publicadas en el artículo de referencia de la Base de Datos 2 y las representadas en BioVisor.

Como puede observarse en la Figura 6.2, las señales representadas en BioVisor (Figura 6.2b) reproducen la morfología y la evolución temporal de las publicadas en el artículo (Figura 6.2a), manteniendo además la correspondencia con los intervalos de las sesiones de música relajante y música estresante. En esta comparación únicamente debe considerarse la primera sección del registro, correspondiente a las fases de música relajante y música estresante, y no la parte de música generada, que queda fuera


del alcance de la comparación con el artículo de referencia.

En concreto, el periodo marcado en azul oscuro en la imagen del artículo (Figura 6.2a) se corresponde con la misma sesión que aparece señalada en amarillo en las señales representadas por BioVisor (Figura 6.2b). Atendiendo a dicho intervalo, se aprecian varias correspondencias claras entre ambas representaciones. La señal de temperatura presenta un pico durante el periodo de descanso posterior a esa sesión, coincidiendo en ambas figuras. En la señal de BVP se observa una zona de amplitud reducida en el mismo tramo, y la señal de EDA muestra la misma distorsión —una sucesión de picos irregulares— durante el descanso que sigue a la sesión de música estresante. Estas coincidencias validan el proceso de carga, la sincronización temporal y la delimitación de las fases experimentales para la Base de Datos 2.


Una vez comprobada la fiabilidad de la representación con el sujeto disponible en el artículo, se representaron el resto de los sujetos de la base (del sujeto 1 al sujeto 10 sin contar el 9) con el fin de verificar que, en todos los casos, las señales se cargan y se visualizan correctamente y que sus resultados pueden observarse sin incidencias. Dichas representaciones se recogen en la Figura 6.3.




(a) Sujeto 1




(b) Sujeto 2




(c) Sujeto 3



(d) Sujeto 4



(e) Sujeto 5



(f) Sujeto 6




Figura 6.3 Representación en BioVisor de las señales fisiológicas registradas mediante los dispositivos Empatica para el resto de sujetos de la Base de Datos 2.

A la vista de estas representaciones, puede asumirse que la estimación del sistema es coherente. Por un lado, se observan picos de estrés al inicio del experimento y al comienzo de cada sesión, lo que resulta esperable, ya que en esos instantes el estrés surge de la incertidumbre del sujeto al no saber qué va a ocurrir. Por otro lado, los picos de estrés aparecen principalmente durante la sesión de música estresante, lo que confirma que la estimación tiene sentido fisiológico. Estos resultados respaldan lo planteado en el estudio: la música estresante efectivamente induce estrés en la persona y, por tanto, afecta a la concentración durante la realización de las tareas.

6.3. Resultados de detección de estrés con Biopac (Base de datos 1)

En esta sección se presentan los resultados de **detección de estrés** obtenidos con las señales fisiológicas registradas mediante el equipo Biopac, que constituyen la **Base de datos 1**. Esta base reúne las señales de cinco sujetos adquiridas durante el protocolo experimental, e incluye las seis señales reconocidas por la aplicación: ECG, EDA, EMG, PPG, RESP y SKT. Sobre cada una de ellas se evalúan los cuatro clasificadores implementados —RF, LightGBM, SVM y KNN— con el objetivo de valorar su capacidad para *discriminar* entre las fases de estrés y de no estrés.

La exposición de los resultados sigue un orden **de lo particular a lo general**. En primer lugar, se analiza en detalle un sujeto representativo, mostrando para cada señal el *diagrama de cajas* de las características por fase y la evolución temporal de la probabilidad de estrés, junto con el AUC alcanzado por cada modelo. A continuación, se estudia el comportamiento global de ese mismo sujeto

combinando todas las señales disponibles. Por último, se presentan los resultados del **modelo global** entrenado sobre la Base de datos 1 completa, evaluado sobre el conjunto de sujetos, lo que permite valorar el rendimiento general del sistema con este dispositivo.

6.3.1. Análisis detallado de un sujeto representativo

Se presenta en detalle el análisis de un sujeto de la Base de datos 1, mostrando el comportamiento de los cuatro modelos sobre todas las señales disponibles. Para cada señal se incluye la curva ROC de los cuatro clasificadores, la evolución temporal de la probabilidad de estrés y los diagramas de caja de las características por fase; además, se muestran las representaciones globales que combinan todas las señales.

A modo de ejemplo, en este apartado se muestran los gráficos que devuelve la aplicación al ejecutar el análisis del sujeto 1 de la Base de datos 1 sobre la señal de electrocardiograma (ECG). Para cada uno de los cuatro modelos (RF, LightGBM, SVM y KNN) se presentan el diagrama de caja de las características por fase y la evolución temporal de la probabilidad de estrés estimada (Figuras 6.4-6.7).




Figura 6.4 Resultados del modelo Random Forest sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.




Figura 6.5 Resultados del modelo LightGBM sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.




Figura 6.6 Resultados del modelo SVM sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.




Figura 6.7 Resultados del modelo KNN sobre la señal de ECG del sujeto 1 de la Base de datos 1: (a) Diagrama de cajas, (b) Probabilidad de estrés.

Tabla 6.2 AUC obtenido por cada modelo y señal para el sujeto representativo de la Base de datos 1.

Señal	Random Forest	LightGBM	SVM	KNN
ECG	0,873	0,828	0,888	0,885
EDA	0,471	0,436	0,503	0,463
EMG	0,943	0,935	0,954	0,946
PPG	0,714	0,730	0,577	0,655
RESP	0,872	0,847	0,745	0,800
SKT	0,934	0,913	0,881	0,887

Como puede observarse en la Tabla 6.2, la mayoría de las señales alcanzan valores de AUC **elevados** para este sujeto. Destaca especialmente el EMG, que supera un AUC de 0,93 con los cuatro clasificadores y alcanza el valor máximo de toda la tabla con SVM (0,954), así como la SKT y el ECG, que se mantienen de forma consistente por encima de 0,88 y 0,82 respectivamente. La señal de respiración (RESP) se sitúa en un rango intermedio-alto, con valores comprendidos aproximadamente entre 0,75 y 0,87 según el modelo, mientras que el PPG presenta un comportamiento más irregular, oscilando entre 0,577 (SVM) y 0,730 (LightGBM).

La señal que presenta un rendimiento **claramente inferior** es la EDA, con valores de AUC comprendidos entre 0,436 (LightGBM) y 0,503 (SVM), es decir, prácticamente equivalentes al azar (0,5) para este sujeto. Este comportamiento resulta coherente con la naturaleza de la actividad electrodérmica,

cuya respuesta es más lenta y variable entre sujetos, lo que dificulta que en un único sujeto proporcione una separación tan nítida entre fases como la que ofrecen las señales cardíacas o musculares.

Esta pérdida de capacidad discriminativa se aprecia también de forma visual en el **diagrama de cajas** de la EDA, que representa la distribución de las cuatro características extraídas por ventana —media, desviación típica, RMS y amplitud pico a pico— separadas por fase (*calming*, *stress* y reposo). En él, la línea central de cada caja indica la **mediana**, la caja delimita el *rango intercuartílico* (del percentil 25 al 75) y los bigotes recogen la dispersión del resto de valores. Para que una característica resulte útil al clasificador, las cajas de las fases *calming* y *stress* deben aparecer **desplazadas entre sí**, de modo que exista una separación clara entre sus distribuciones. En el caso de la EDA, sin embargo, las cajas de ambas fases se **solapan de forma notable** y comparten medianas muy próximas, lo que refleja que sus características apenas cambian entre reposo y estrés para este sujeto. Este solapamiento es la causa directa del AUC cercano al azar: al no existir un desplazamiento apreciable entre las distribuciones, el modelo no dispone de un margen fiable sobre el que trazar la frontera de decisión. Por el contrario, las señales cardíacas y musculares presentan cajas mucho más *diferenciadas* entre fases, lo que se traduce en los valores de AUC sensiblemente superiores comentados anteriormente.

En conjunto, estos resultados muestran que el sistema es capaz de detectar el estrés de forma fiable a partir de la mayoría de las señales fisiológicas registradas con Biopac, y que el rendimiento depende más de la *modalidad* empleada que del *clasificador* concreto, ya que los cuatro modelos ofrecen valores muy similares para cada señal, con la EDA como principal excepción.

6.3.2. Resultados globales de sujeto demostrativo de Biopac

Se agregan los resultados de los cinco sujetos de la Base de datos 1 para valorar el comportamiento general del sistema con las señales de Biopac.




Figura 6.8 Gráficas generales del sujeto 1 de la Base de datos 1: (a) intervalo RR obtenido a partir de la señal de ECG; (b) frecuencia respiratoria obtenida a partir de la señal de respiración.




Figura 6.9 Resultados globales del modelo Random Forest para el sujeto 1 de la Base de datos 1: (a) probabilidad de estrés combinada de todas las señales; (b) mapa de calor de la envolvente de la probabilidad media de estrés.




Figura 6.10 Resultados globales del modelo LightGBM para el sujeto 1 de la Base de datos 1: (a) probabilidad de estrés combinada de todas las señales; (b) mapa de calor de la envolvente de la probabilidad media de estrés.




Figura 6.11 Resultados globales del modelo SVM para el sujeto 1 de la Base de datos 1: (a) probabilidad de estrés combinada de todas las señales; (b) mapa de calor de la envolvente de la probabilidad media de estrés.

6.4. Resultados de detección de estrés con Empatica (Base de datos 2)

6.4.1. Análisis en detalle del sujeto descriptivo de la Base de datos 2

En esta sección se presenta un análisis detallado del área bajo la curva ROC (AUC) obtenido para un sujeto representativo de la Base de datos 2. Se evalúa el rendimiento de los cuatro modelos de clasificación considerados (RF, LightGBM, SVM y KNN) sobre las señales registradas por el dispositivo Empatica: BVP, EDA, TEMP, ACC y HR, siguiendo el mismo esquema de análisis empleado anteriormente para la Base de datos 1.

La Tabla 6.3 recoge los valores de AUC obtenidos para cada combinación de modelo y señal. En términos generales, la mayoría de los resultados presentan valores superiores a 0,5, lo que indica que los clasificadores poseen una capacidad de discriminación mejor que la de una clasificación aleatoria y, por tanto, se sitúan por encima de la diagonal de referencia de la curva ROC. No obstante, algunas combinaciones, especialmente en la señal de frecuencia cardíaca (HR), muestran valores próximos o ligeramente inferiores a dicho umbral.

Tabla 6.3 AUC obtenido por cada modelo y señal para el sujeto representativo de la Base de datos 2.

Señal	Random Forest	LightGBM	SVM	KNN
ACC	0.792	0.780	0.840	0.820
BVP	0.716	0.558	0.736	0.691
EDA	0.724	0.728	0.718	0.682
HR	0.649	0.553	0.584	0.400
TEMP	0.881	0.811	0.922	0.877

A partir de estos resultados se observa que las señales que ofrecen mayor poder discriminativo son la temperatura cutánea (TEMP) y el acelerómetro (ACC). La TEMP alcanza el mejor resultado global con SVM (0,922) y se mantiene por encima de 0,81 con los cuatro clasificadores, mientras que el ACC se sitúa de forma consistente entre 0,78 y 0,84. Las señales EDA y BVP ofrecen un rendimiento **intermedio**: la EDA se mantiene bastante estable en torno a 0,68–0,73, y el BVP resulta más dependiente del modelo, con valores que van de 0,558 (LightGBM) a 0,736 (SVM).


Por el contrario, la señal de frecuencia cardíaca (HR) presenta el **menor poder discriminativo**, con valores de AUC comprendidos entre 0,400 (KNN) y 0,649 (RF); en el caso de KNN queda incluso por debajo del azar. Este comportamiento es coherente con la naturaleza de la señal de HR de **Empatica**, que se registra a una frecuencia de muestreo muy baja (1 Hz) y proporciona, por tanto, muy pocas muestras por ventana, lo que limita la riqueza de las características que pueden extraerse de ella.

En conjunto, al igual que ocurría con la Base de datos 1, se aprecia que el rendimiento depende más de la *modalidad* de la señal que del *clasificador* empleado, ya que los cuatro modelos ofrecen valores razonablemente parecidos para cada señal, con la HR como principal excepción.


6.4.2. Resultados globales de la Base de datos 2 completa

En esta sección se presentan las probabilidades de estrés obtenidas mediante el modelo global de RF para los diez sujetos de la Base de datos 2 empleando las señales del dispositivo Empatica. Cada gráfica representa la evolución temporal de la probabilidad estimada de pertenencia a la clase de estrés,


permitiendo analizar el comportamiento del clasificador a lo largo de las distintas fases del protocolo experimental.




(a)



(b)




(c)

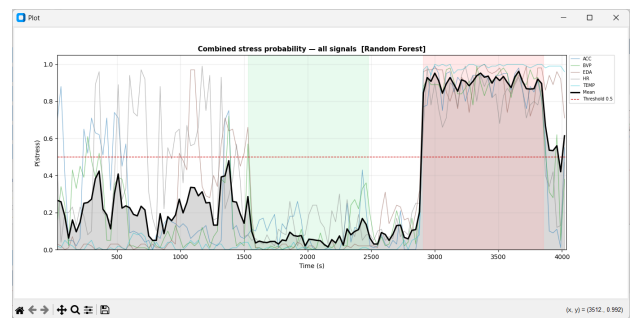


(d)


Figura 6.14 Probabilidad de estrés estimada mediante el modelo global de Random Forest para los sujetos 1 a 4 de la Base de datos 2. (a) Sujeto 1. (b) Sujeto 2. (c) Sujeto 3. (d) Sujeto 4.




(a)



(b)




(c)




(d)

Figura 6.15 Probabilidad de estrés estimada mediante el modelo global de Random Forest para los sujetos 5 a 8 de la Base de datos 2. (a) Sujeto 5. (b) Sujeto 6. (c) Sujeto 7. (d) Sujeto 8.



(a)



(b)

Figura 6.16 Probabilidad de estrés estimada mediante el modelo global de Random Forest para los sujetos 9 y 10 de la Base de datos 2. (a) Sujeto 9. (b) Sujeto 10.

De forma general, puede observarse que en numerosos sujetos aparecen incrementos de la probabilidad de estrés antes del comienzo de las diferentes sesiones. Este comportamiento puede atribuirse al estado de anticipación del participante, ya que es razonable asumir que existe cierta tensión al desconocer qué estímulo va a presentarse a continuación. Del mismo modo, también se aprecian incrementos al inicio de varias de las sesiones musicales, coincidiendo con el cambio de estímulo.

No obstante, también se observa que algunos sujetos no presentan un aumento significativo de la probabilidad de estrés durante los periodos correspondientes a la música estresante. Este comportamiento es esperable, ya que la respuesta fisiológica frente a un estímulo musical depende en gran medida de las características individuales de cada participante, así como de sus preferencias y percepción subjetiva de la música empleada.

Es importante considerar, además, que para obtener estos resultados fue necesario combinar las señales registradas en las muñecas izquierda y derecha, asumiendo que ambas adquisiciones estaban perfectamente sincronizadas en el tiempo. Como se ha comentado en la sección anterior, pequeños desfases temporales entre ambas señales pueden introducir ligeras alteraciones durante el proceso de alineación y preprocesado, afectando parcialmente a la estimación de las probabilidades. A pesar de esta limitación, el comportamiento general observado es coherente con el desarrollo del experimento, por lo que puede asumirse que los resultados obtenidos representan de forma adecuada la evolución del nivel de estrés de los participantes.

6.5. Comparación entre dispositivos y discusión

En este apartado se comparan los resultados obtenidos con los dispositivos Biopac y Empatica a partir de las dos bases de datos usadas en el estudio. Es importante tener en cuenta que cada dispositivo se ha evaluado sobre un conjunto de datos distinto, así que esta comparación no debe verse como un enfrentamiento directo entre ambos, sino como una valoración de cómo se comporta cada uno dentro de su propia base de datos.

La Tabla 6.4 resume las principales características de cada dispositivo, las señales empleadas y el comportamiento general que se observó durante la clasificación.

Tabla 6.4 Comparación general entre los dispositivos Biopac y Empatica.

Característica	Biopac	Empatica
Señales utilizadas	ECG, EDA, EMG, PPG, RESP y SKT	BVP, EDA, TEMP, ACC y HR
Número de señales	6	5
Mejores señales	SKT, EMG y ECG	TEMP y ACC
Señal más débil	EDA	HR
Modelo con mejor comportamiento	Random Forest	Random Forest
Rendimiento general	Muy alto	Alto

A la vista de los resultados, se aprecia que **Biopac alcanza en general valores de AUC más altos que Empatica**. En la mayoría de sus señales se consiguen valores cercanos o superiores a 0,9, lo que indica que el sistema distingue correctamente entre las situaciones de estrés y de relajación. Los resultados de **Empatica** son algo más modestos, situándose la mayoría entre 0,8 y 0,9, aunque en casi todos los casos siguen estando claramente por encima de lo que daría una clasificación al azar.

Esta diferencia se explica sobre todo por la **naturaleza de cada dispositivo**. **Biopac** es un sistema pensado para registrar señales fisiológicas en el laboratorio, con sensores específicos que ofrecen medidas de mucha calidad y con poco ruido. **Empatica**, en cambio, es un dispositivo portátil pensado para monitorizar al usuario de forma continua en su día a día. Esto es una gran ventaja en cuanto a comodidad y facilidad de uso, pero también hace que sus señales sean más sensibles al movimiento y a otros factores externos.

Precisamente el caso del acelerómetro (ACC) en Empatica merece una lectura prudente. Aunque obtiene valores de AUC elevados, conviene recordar que el ACC mide *movimiento* y no una respuesta fisiológica de estrés propiamente dicha, por lo que su buen rendimiento podría reflejar en parte diferencias de actividad entre las fases del protocolo más que la reacción de estrés en sí. Debe interpretarse, por tanto, más como una señal de contexto que como un marcador fisiológico directo.

Además, en la *Base de datos 2* hubo que **sincronizar y combinar las señales de las muñecas izquierda y derecha**. Este proceso daba por hecho que las dos adquisiciones estaban perfectamente alineadas en el tiempo, pero pequeños desfases entre ellas pueden haber alterado un poco las características extraídas y haber empeorado ligeramente el rendimiento de los modelos. Es razonable pensar que, si se trabajara con las señales originales perfectamente sincronizadas, los resultados de Empatica podrían mejorar.

En cuanto a los algoritmos de clasificación, **RF ha sido el modelo más estable** en las dos bases

de datos: consigue buenos resultados sin importar demasiado el tipo de señal. LightGBM se comporta de forma muy parecida en varias señales, mientras que SVM y KNN son más irregulares y dependen bastante del tipo de información fisiológica que se analice.

En conjunto, puede concluirse que, dentro de las condiciones de este estudio, **Biopac ofrece un mejor rendimiento que Empatica en la detección del estrés**. Aun así, esta diferencia hay que interpretarla teniendo en cuenta dos cosas: que cada dispositivo se evaluó sobre una base de datos distinta y que **Empatica** tiene una ventaja muy importante, y es que **permite una monitorización continua con un dispositivo portátil y poco invasivo**. Esto lo convierte en una alternativa muy interesante para aplicaciones reales, donde la comodidad del usuario es clave, aunque a cambio se pierda un poco de precisión en la clasificación.

6.5.1. Validación LOSO

Con el fin de evaluar la capacidad de **generalización** del modelo a sujetos no vistos durante el entrenamiento, se llevó a cabo una validación mediante la estrategia LOSO, descrita en el Capítulo de Desarrollo. A diferencia de la validación cruzada empleada en el análisis individual, en este caso todas las ventanas pertenecientes a un mismo sujeto permanecen siempre en el mismo conjunto: en cada iteración el clasificador se entrena con los registros de todos los sujetos menos uno y se evalúa exclusivamente sobre el sujeto restante, repitiendo el proceso hasta cubrir a todos los participantes.

Esta metodología constituye una evaluación **considerablemente más exigente**, ya que obliga al modelo a identificar patrones fisiológicos *comunes* entre distintos individuos e impide que se apoye en características propias de un participante concreto. Para ello se reutilizaron exactamente las mismas etapas de extracción de características, etiquetado automático y preprocesado implementadas en **Bio-Visor**, de modo que la única diferencia respecto al análisis anterior fuese la estrategia de validación.

La validación LOSO se realizó empleando el clasificador *Random Forest* (RF), por resultar el **más estable** en el análisis individual previo.

Resultados LOSO en la Base de datos 1 (Biopac)

La Tabla 6.5 recoge el AUC obtenido para cada sujeto de la Base de datos 1 en la validación LOSO, junto con su media y desviación típica.

Tabla 6.5 Resultados de la validación Leave-One-Subject-Out (modelo multimodal fusionado) para la Base de datos 1 (Biopac).

Sujeto	AUC LOSO
Sujeto 1	0.971
Sujeto 2	0.214
Sujeto 3	0.963
Sujeto 4	0.845
Sujeto 5	0.413
Media $\pm$ sd	0.681 $\pm$ 0.310

Resultados LOSO en la Base de datos 2 (Empatica)

La Tabla 6.6 recoge el AUC obtenido para cada sujeto de la Base de datos 2 en la validación LOSO, junto con su media y desviación típica.

Tabla 6.6 Resultados de la validación Leave-One-Subject-Out (modelo multimodal fusionado) para la Base de datos 2 (Empatica).

Sujeto	AUC LOSO
Sujeto 1	0.451
Sujeto 2	0.628
Sujeto 3	0.714
Sujeto 4	0.702
Sujeto 5	0.892
Sujeto 6	0.493
Sujeto 7	0.260
Sujeto 8	0.554
Sujeto 9	0.168
Sujeto 10	0.382
Media $\pm$ sd	0.524 $\pm$ 0.209

Discusión de los resultados LOSO

Los resultados de la validación LOSO contrastan de forma **acusada** con los obtenidos en el análisis *intra-sujeto*. Mientras que dentro de un mismo sujeto los clasificadores alcanzaban valores de AUC muy elevados, al exigir la generalización a sujetos no vistos el rendimiento cae hasta valores **próximos al azar** en promedio: 0,675 en la Base de datos 1 (Biopac) y 0,524 en la Base de datos 2 (Empatica).

Más revelador que la media es su **elevada dispersión**, especialmente en la Base de datos 1 ($sd = 0,309$). El AUC por sujeto oscila entre valores altos (Sujeto 1, 0,963; Sujeto 3, 0,950) y valores *por debajo del azar* (Sujeto 2, 0,193; Sujeto 5, 0,432). Un AUC sensiblemente inferior a 0,5 no indica ausencia de información, sino que la **frontera de decisión aprendida se invierte** para ese sujeto: los patrones que el modelo asocia al estrés en el resto de participantes se manifiestan de forma opuesta en él. Esto evidencia que la firma fisiológica del estrés es **marcadamente individual** y que la media, calculada sobre tan solo cinco y diez sujetos respectivamente, resulta poco representativa por sí sola. La Base de datos 2 presenta un comportamiento análogo, con sujetos que generalizan razonablemente (Sujeto 5, 0,847) frente a otros claramente por debajo del azar (Sujeto 9, 0,258; Sujeto 7, 0,268).

En conjunto, estos resultados confirman el que constituye el **principal hallazgo** de este trabajo: pese al alto rendimiento intra-sujeto, la capacidad de **generalización entre sujetos es limitada**. Este comportamiento es coherente con la literatura sobre detección de estrés, en la que la fuerte *variabilidad interindividual* —diferencias en la línea base fisiológica, en la magnitud de la respuesta y en las estrategias de afrontamiento de cada persona— constituye una de las principales dificultades. Lejos de invalidar la herramienta, este resultado delimita con honestidad su alcance: **BioVisor** resulta eficaz para caracterizar y detectar el estrés *dentro de un mismo individuo*, pero la construcción de un modelo verdaderamente *universal* exigiría un número de sujetos considerablemente mayor y, previsiblemente, técnicas de normalización o adaptación al dominio específicas de cada individuo.

7. Conclusiones y líneas futuras

En este Trabajo de Fin de Grado se ha desarrollado **BioVisor**, una aplicación de escritorio para la visualización de señales fisiológicas multimodales y la detección de estrés mediante aprendizaje automático. La herramienta integra en un mismo entorno la carga y el acondicionamiento de las señales, su representación sincronizada, la extracción de características por ventanas temporales, el etiquetado a partir del protocolo experimental y el entrenamiento de cuatro clasificadores (RF, LightGBM, SVM y KNN), cumpliendo así los objetivos planteados al inicio del proyecto.

Uno de los aspectos centrales del sistema es el **criterio de etiquetado**. En las dos bases de datos utilizadas, el entrenamiento y la evaluación se realizan con las **etiquetas del protocolo** (fases de *calming* y *veering*), lo que permite garantizar que el rendimiento medido refleje la capacidad real de discriminación entre fases.

En cuanto a los resultados, conviene distinguir **dos niveles de análisis** que ofrecen conclusiones muy distintas. En el análisis *intra-sujeto*, evaluado mediante validación cruzada, el sistema alcanza valores de AUC elevados en la mayoría de las señales, especialmente con **Biopac**, donde señales como la SKT, el EMG o el ECG superan de forma consistente un AUC de 0,94. Estos resultados muestran que, dentro de un mismo sujeto, el sistema separa correctamente las fases de estrés y de relajación, y que el rendimiento depende más de la *modalidad* de la señal que del *clasificador* empleado.

Sin embargo, la validación **Leave-One-Subject-Out** (LOSO) ofrece una imagen mucho más realista y matizada. Al evaluar la capacidad de generalización a sujetos no vistos, el rendimiento se reduce sensiblemente. La mayoría de las señales tomadas de forma individual quedan próximas al azar, si bien el modelo que fusiona todas las señales conserva cierta capacidad discriminativa, con un AUC medio de 0,681 en Biopac y 0,524 en Empatica y una variabilidad muy alta entre sujetos. Esto pone de manifiesto que, aunque el modelo funciona bien *dentro* de un mismo individuo, su **capacidad de generalización entre personas es todavía limitada**, algo esperable dado el reducido número de participantes (cinco en Biopac y diez en Empatica) y la elevada variabilidad fisiológica entre sujetos. Este contraste entre ambas validaciones constituye, de hecho, una de las conclusiones más importantes del trabajo: subraya la necesidad de emplear estrategias de evaluación rigurosas para no sobreestimar el rendimiento de este tipo de sistemas.

Respecto a la comparación entre dispositivos, **Biopac** ofrece señales de mayor calidad y, por tanto, mejores resultados intra-sujeto, mientras que **Empatica** aporta la ventaja de una monitorización portátil y no invasiva, lo que lo convierte en una alternativa interesante para escenarios de uso real pese a su menor precisión.

Como **líneas de trabajo futuro**, la más prioritaria es **ampliar el número de participantes y su diversidad**, ya que es la principal limitación para lograr modelos que generalicen entre sujetos. Además, sería interesante explorar arquitecturas de aprendizaje profundo capaces de aprender representaciones más robustas y extender la validación LOSO al resto de clasificadores para contrastar su comportamiento. Por último, la propia herramienta **BioVisor** puede seguir ampliándose con nuevas señales, nuevos dispositivos y funcionalidades adicionales, aprovechando su arquitectura modular para facilitar futuras extensiones.

Bibliografía

- [1] S. Khazaei, S. Parshi, S. Alam, M. R. Amin y R. T. Faghih, *A Multimodal Dataset for Investigating Working Memory in Presence of Music*, ver. 1.0.0, PhysioNet, 2025. DOI: 10.13026/6vh4-dk68. dirección: <https://doi.org/10.13026/6vh4-dk68>.
- [2] PhysioNet. “Regulation of Brain Cognitive States through Auditory, Gustatory, and Olfactory Stimulation with Wearable Monitoring – Experiment 1”, visitado 4 de jul. de 2026. dirección: https://physionet.org/content/brain-wearable-monitoring/1.0.0/Experiment_1/#files-panel.
- [3] PhysioNet. “PhysioNet”, visitado 3 de jul. de 2026. dirección: <https://physionet.org/>.
- [4] P. Mukli, A. Yabluchanskiy y T. Csipo, *Mental workload during n-back task captured by functional near-infrared spectroscopy and transcranial Doppler sonography*, ver. 1.0.0, PhysioNet, abr. de 2021. dirección: <https://physionet.org/content/mental-fnirs/1.0/>.
- [5] H. Fekri Azgomi, L. Branco, M. R. Amin, S. Khazaei y R. T. Faghih, *Regulation of Brain Cognitive States through Auditory, Gustatory, and Olfactory Stimulation with Wearable Monitoring*, ver. 1.0.0, PhysioNet, dic. de 2023. DOI: 10.13026/jr6f-wc85. dirección: <https://doi.org/10.13026/jr6f-wc85>.
- [6] S. Khazaei, S. Parshi, S. Alam, M. R. Amin y R. T. Faghih, *A Multimodal Dataset for Investigating Working Memory in Presence of Music*, ver. 1.0.0, PhysioNet, feb. de 2025. DOI: 10.13026/6vh4-dk68. dirección: <https://doi.org/10.13026/6vh4-dk68>.
- [7] M. K. Grzeszczyk et al., *CogWear: Can we detect cognitive effort with consumer-grade wearables?*, ver. 1.0.0, PhysioNet, mar. de 2023. DOI: 10.13026/5f6t-b637. dirección: <https://doi.org/10.13026/5f6t-b637>.
- [8] P. Cho, J. Kim, B. Bent y J. Dunn, *BIG IDEAs Lab Glycemic Variability and Wearable Device Data*, ver. 1.1.3, PhysioNet, 2026. DOI: 10.13026/zthx-5212. dirección: <https://doi.org/10.13026/zthx-5212>.
- [9] A. Hongn, F. Bosch, L. E. Prado, J. M. Ferrández y M. P. Bonomini, *Wearable Device Dataset from Induced Stress and Structured Exercise Sessions*, ver. 1.0.1, PhysioNet, jun. de 2025. DOI: 10.13026/he0v-tf17. dirección: <https://doi.org/10.13026/he0v-tf17>.
- [10] Quirónsalud. “Electrocardiograma (ECG)”, visitado 25 de mayo de 2026. dirección: <https://www.quironsalud.com/es/pruebas-diagnosticas/electrocardiograma-ecg>.
- [11] Medicina General Universal. “Qué es un electrocardiograma: interpretación y significado”, visitado 25 de mayo de 2026. dirección: <https://medicinageneraluniversal.blogspot.com/2017/01/que-es-un-electrocardiograma.html>.
- [12] Red Iberoamericana de Tecnologías Aplicadas a la Diabetes. “Actividad electro-dérmica (EDA)”, visitado 25 de mayo de 2026. dirección: <https://ritadiab.umh.es/eda/>.
- [13] HM Hospitales. “Electromiograma: qué es, cómo funciona y para qué se utiliza”, visitado 25 de mayo de 2026. dirección: <https://www.hmhospitales.com/blog/electromiorama-que-es-para-sirve/>.

- [14] LibreTexts Español. “9.19: Control del Sistema Nervioso de la Tensión Muscular”, visitado 4 de jul. de 2026. dirección: [https://espanol.libretexts.org/Bookshelves/Salud/Salud_y_estado_fisico/Libro%3A_Lifetime_Fitness_and_Wellness_\(Lumen\)/03%3A_Unidad_3/09%3A_Fuerza_y_Resistencia_Muscular/9.19%3A_Control_del_Sistema_Nervioso_de_la_Tensi%C3%B3n_Muscular](https://espanol.libretexts.org/Bookshelves/Salud/Salud_y_estado_fisico/Libro%3A_Lifetime_Fitness_and_Wellness_(Lumen)/03%3A_Unidad_3/09%3A_Fuerza_y_Resistencia_Muscular/9.19%3A_Control_del_Sistema_Nervioso_de_la_Tensi%C3%B3n_Muscular).
- [15] ResearchGate. “Señal electromiográfica. Se observan los cambios de amplitud en un registro”, visitado 25 de mayo de 2026. dirección: https://www.researchgate.net/figure/Figura-1-Senal-electromiografica-Se-observan-los-cambios-de-amplitud-en-un-registro_fig1_331136424.
- [16] AcademiaLab. “Fotopletismograma”, visitado 25 de mayo de 2026. dirección: <https://academia-lab.com/enciclopedia/fotopletismograma/>.
- [17] J. Castillo, D. Morales, R. García-Ovejero y L. Morales, “An Advanced Bio-Inspired Photo-Plethysmography (PPG) and ECG Pattern Recognition System for Medical Assessment”, *Sensors*, vol. 18, n° 2, pág. 405, 2018. visitado 25 de mayo de 2026. dirección: <https://www.mdpi.com/1424-8220/18/2/405>.
- [18] Getinge. “Parámetros avanzados de monitorización: HR, PR”, visitado 25 de mayo de 2026. dirección: <https://www.getinge.com/es/perspectivas/articulos/cuidados-intensivos/parametros-de-monitorizacion-avanzada/hr-pr/>.
- [19] M. R. Esco y A. A. Flatt. “Ultra-Short-Term Heart Rate Variability Indexes at Rest and Post-Exercise in Athletes: Evaluating the Agreement with Accepted Recommendations”, visitado 6 de jul. de 2026. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4126289/>.
- [20] K. Iwasaki, C. Reynolds y M. Ishikawa, “Toward Emotional Well-Being: Staying Calm with ECG Feedback”, en *Proceedings of the AAAI Conference on Artificial Intelligence*, Association for the Advancement of Artificial Intelligence (AAAI). visitado 6 de jul. de 2026. dirección: <https://aaai.org/papers/07755-7755-toward-emotional-well-being-staying-calm-with-ecg-feedback/>.
- [21] Enfermería Buenos Aires. “Respiración: signos vitales”, visitado 25 de mayo de 2026. dirección: <https://enfermeriabuenosaires.com/respiracion-signos-vitales/>.
- [22] MESI. “Cómo realizar correctamente una espirometría”, visitado 25 de mayo de 2026. dirección: <https://mesimedical.com/es/noticias/como-realizar-correctamente-una-espirometria>.
- [23] LookForMedical. “Temperatura cutánea. Buscador médico. Preguntas frecuentes”, visitado 25 de mayo de 2026. dirección: <https://lookformedical.com/es/faq/temperatura-cut%C3%A1nea>.
- [24] Centro de Biofeedback. “Biofeedback y temperatura periférica”, visitado 25 de mayo de 2026. dirección: <https://centrobiofeedback.es/biofeedback-y-temperatura-periferica/>.
- [25] BIOPAC Systems, Inc. “BSL 4 Tutorial (Español)”, visitado 6 de jul. de 2026. dirección: <https://www.biopac.com/wp-content/uploads/bsl-4-tutorial-es.pdf>.
- [26] Empatica Inc. “Empatica E4 Technical Specifications”, visitado 6 de jul. de 2026. dirección: https://box.empatica.com/documentation/20141119_E4_TechSpecs.pdf.
- [27] J. F. Laborin Álvarez y J. M. Muñoz Cano, “Biomarcadores en la medición del estrés: una revisión sistemática”, *Ansiedad y Estrés*, 2018. visitado 25 de mayo de 2026. dirección: <https://www.elsevier.es/es-revista-ansiedad-estres-242-articulo-biomarcadores-medicion-del-estres-una-S1134793718300472>.
- [28] Wikipedia. “Aprendizaje automático”, visitado 25 de mayo de 2026. dirección: https://es.wikipedia.org/wiki/Aprendizaje_autom%C3%A1tico.

- [29] A. Rojo García, “Detección automática de arritmias cardíacas mediante técnicas de aprendizaje automático aplicadas a señales ECG”, Escuela Politécnica Superior, Trabajo Fin de Grado, Universidad de Alicante, 2025.
 - [30] Wikipedia. “Random forest”, visitado 25 de mayo de 2026. dirección: https://es.wikipedia.org/wiki/Random_forest.
 - [31] D. Wei. “10 Must-Know Models for ML Beginners: Random Forest”, visitado 25 de mayo de 2026. dirección: <https://medium.com/@weidagang/demystifying-machine-learning-models-random-forest-f992dc50b427>.
 - [32] Wikipedia. “LightGBM”, visitado 25 de mayo de 2026. dirección: <https://en.wikipedia.org/wiki/LightGBM>.
 - [33] Ichi.pro. “Clasificación de la máquina de vectores de soporte (SVM)”, visitado 25 de mayo de 2026. dirección: <https://ichi.pro/es/clasificacion-de-la-maquina-de-vectores-de-soporte-svm-111570773178597>.
 - [34] GeeksforGeeks. “K-Nearest Neighbor (KNN) Algorithm”, visitado 25 de mayo de 2026. dirección: <https://www.geeksforgeeks.org/k-nearest-neighbours/>.
 - [35] S. Khazaei, S. Parshi, S. Alam, M. R. Amin y R. T. Faghih, “A multimodal dataset for investigating working memory in presence of music: a pilot study”, *Frontiers in Neuroscience*, vol. 18, pág. 1406814, 2024. DOI: 10.3389/fnins.2024.1406814. dirección: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2024.1406814/full>.
 - [36] Python Software Foundation. “Python Programming Language”, visitado 3 de jul. de 2026. dirección: <https://www.python.org/>.
 - [37] Microsoft. “Visual Studio Code”, visitado 3 de jul. de 2026. dirección: <https://code.visualstudio.com/>.
 - [38] GitHub, Inc. “GitHub”, visitado 3 de jul. de 2026. dirección: <https://github.com/>.
 - [39] T. Fawcett, “An introduction to ROC analysis”, *Pattern Recognition Letters*, vol. 27, n° 8, págs. 861-874, 2006. DOI: 10.1016/j.patrec.2005.10.010.
-

Lista de Acrónimos y Abreviaturas

ACC	Acelerometría.
AUC	Área Bajo la Curva.
BPM	Latidos Por Minuto.
BVP	Volumen de Pulso Sanguíneo.
CSV	Comma-Separated Values.
ECG	Electrocardiograma.
EDA	Actividad Electrodermica.
EFB	Exclusive Feature Bundling.
EMG	Electromiograma.
GOSS	Gradient-Based One-Side Sampling.
GSR	Galvanic Skin Response.
GUI	Graphical User Interface.
HF	High Frequency.
HHA	Eje Hipotálamo-Hipófiso-Adrenal.
HR	Frecuencia Cardíaca.
HRV	Variabilidad de la Frecuencia Cardíaca.
KNN	K-Nearest Neighbours.
LF	Low Frequency.
LightGBM	Light Gradient Boosting Machine.
LOSO	Validación Leave-One-Subject-Out.
ML	Machine Learning.
NaN	Not a Number.
pNN50	Porcentaje de Intervalos NN que difieren más de 50 ms.
PPG	Fotopletismografía.
QRS	Complejo QRS (despolarización ventricular).
RBF	Función de Base Radial.
RESP	Señal Respiratoria.
RF	Random Forest.
RMS	Valor Cuadrático Medio.
RMSSD	Root Mean Square of Successive Differences.
ROC	Receiver Operating Characteristic.
RR	Intervalo entre Latidos.
SAM	Eje Simpático-Adrenomedular.
SCL	Nivel de Conductancia de la Piel.
SCR	Respuesta de Conductancia de la Piel.
SKT	Temperatura Cutánea.
SVM	Support Vector Machine.
TEMP	Temperatura Periférica.

TFG Trabajo Final de Grado.
VSC Visual Studio Code.

A. Anexo I: Manual de BioVisor

13 de julio de 2026



Manual de BioVisor



Elaborado por
Raquel Gómez

Trabajo realizado en el marco del Trabajo de Fin de Grado
Grado en Ingeniería en Sonido e Imagen en Telecomunicación
Escuela Politécnica Superior
Universidad de Alicante

Índice

1. Introducción	3
1.1. ¿Qué es BioVisor?	3
1.2. Requisitos previos	4
1.3. Preparación de la base de datos	4
2. Primeros pasos con BioVisor	5
2.1. Obtención del proyecto	5
2.2. Instalación de las dependencias	6
2.3. Ejecución de la aplicación	7
3. Explicación de la interfaz	7
3.1. Ventana de configuración de la sesión	7
3.2. Ventana del visor y analizador de señales	8
3.3. Panel de controles de análisis	10
4. Guía de uso paso a paso	10
4.1. Selección de la base de datos	11
4.2. Selección del dispositivo de adquisición	11
4.3. Configuración de las señales	12
4.4. Parámetros de extracción de características	12
4.5. Preprocesado de las señales	12
4.6. Carga de la base de datos	12
5. Visualización de señales	13
5.1. Representación de las señales originales	13
5.2. Navegación entre sujetos y señales	13
5.3. Características fisiológicas derivadas	13
6. Modelos de aprendizaje automático	14

6.1. Entrenamiento de los modelos	14
6.2. Selección del algoritmo de clasificación	15
7. Visualización de resultados	15
7.1. Curvas ROC	15
7.2. Diagramas de cajas	16
7.3. Evolución temporal de la probabilidad de estrés	17
8. Resolución de problemas frecuentes	17
9. Conclusión	18

1. Introducción

En este manual se recopila toda la información necesaria para que cualquier usuario pueda comenzar a utilizar la aplicación **BioVisor**. A lo largo del documento se describen los requisitos de instalación, la estructura general de la aplicación y el funcionamiento detallado de cada una de sus funcionalidades, con el objetivo de permitir el análisis y la visualización de señales fisiológicas de forma sencilla e intuitiva.

Asimismo, se explica el procedimiento para cargar las bases de datos compatibles, configurar los parámetros de procesamiento, ejecutar los modelos de *aprendizaje automático* disponibles e interpretar los resultados obtenidos. Además, se incluyen ejemplos de uso, recomendaciones para la preparación de los datos y la resolución de los problemas más habituales, de modo que se facilite el aprendizaje y se garantice un uso correcto de la aplicación tanto en entornos de investigación como docentes.

1.1. ¿Qué es BioVisor?

BioVisor es una *aplicación de escritorio* desarrollada para la visualización, el procesamiento y el análisis de señales fisiológicas orientadas al estudio de la **detección del estrés** mediante técnicas de aprendizaje automático. La aplicación ha sido diseñada con el objetivo de proporcionar una herramienta sencilla e intuitiva que permita trabajar con diferentes bases de datos fisiológicas sin necesidad de conocimientos avanzados de programación.

BioVisor integra en una única *interfaz gráfica* todas las etapas necesarias para el análisis de señales biomédicas. Entre sus principales funcionalidades se encuentran la carga automática de las bases de datos compatibles, la visualización sincronizada de las señales fisiológicas, la extracción de características mediante *ventanas temporales*, el entrenamiento y evaluación de modelos de aprendizaje automático y la representación gráfica de los resultados obtenidos.

La aplicación es compatible con registros adquiridos mediante los dispositivos **Biopac** y **Empatica E4**, adaptando automáticamente el procesamiento a las características propias de cada sistema de adquisición. De este modo, es posible analizar señales como el electrocardiograma (ECG), la actividad electrodérmica (EDA), la electromiografía (EMG), la fotopletismografía (PPG), la respiración (RESP), la temperatura cutánea (SKT), la señal de volumen del pulso sanguíneo (BVP), la frecuencia cardíaca (HR), la temperatura (TEMP) y la acelerometría (ACC), entre otras.

Además de la representación de las señales originales, BioVisor incorpora herramientas para visualizar *características fisiológicas derivadas*, como los intervalos RR, la frecuencia cardíaca, la frecuencia respiratoria o la **probabilidad de estrés** estimada por los distintos modelos de clasificación implementados. Asimismo, permite comparar el comportamiento de diferentes algoritmos de aprendizaje automático, facilitando el estudio de su rendimiento sobre distintas señales fisiológicas.

En conjunto, BioVisor constituye una plataforma que reúne en un único entorno todas las herramientas necesarias para la exploración, el análisis y la evaluación de datos fisiológicos, facilitando tanto el desarrollo de investigaciones relacionadas con la detección del estrés como su utilización con fines docentes y de aprendizaje.

1.2. Requisitos previos

Para utilizar BioVisor es necesario disponer de un entorno de **Python** correctamente configurado. Se recomienda emplear una versión de **Python 3.9** o superior, junto con las principales librerías científicas y de aprendizaje automático empleadas por la aplicación, entre las que se incluyen:

- **numpy** y **pandas**, para el manejo y procesamiento de los datos.
- **scipy**, para el filtrado y el procesamiento de las señales.
- **scikit-learn**, para el entrenamiento y la evaluación de los modelos de clasificación.
- **lightgbm**, para el algoritmo de clasificación basado en *gradient boosting*.
- **matplotlib**, para la representación gráfica de las señales y los resultados.
- **PyQt** (o el *framework* gráfico correspondiente), para la construcción de la interfaz.

Asimismo, se recomienda instalar un **entorno de desarrollo** que facilite la edición y ejecución del código. En este caso se aconseja utilizar **Visual Studio Code**, un editor gratuito, ligero y compatible con **Python**, que puede descargarse desde su página oficial:

<https://code.visualstudio.com/>.

En caso de disponer de un archivo **requirements.txt** en el repositorio, todas las dependencias pueden instalarse de forma automática tal y como se describe en la Sección 2.

1.3. Preparación de la base de datos

Antes de ejecutar BioVisor es necesario disponer de una base de datos organizada siguiendo la **estructura de directorios** esperada por la aplicación. BioVisor carga automáticamente la información de cada sujeto, por lo que la distribución de carpetas y archivos debe mantenerse sin modificaciones.

La carpeta principal de la base de datos debe contener un directorio para cada sujeto, siguiendo el formato:

```
Base1/  
  Base1_Sujeto1/  
  Base1_Sujeto2/  
  Base1_Sujeto3/  
  ...  
  Base1_SujetoN/
```

A su vez, cada carpeta correspondiente a un sujeto debe contener los directorios asociados a los distintos dispositivos de adquisición y a la información complementaria del experimento. La estructura general es la siguiente:


```
Base1_SujetoX/  
  Biopac data/  
    Empatica_data/  
      SubjectX_Session_Times.csv
```

En el caso de utilizar las señales registradas mediante el sistema **Biopac**, la carpeta **Biopac data** debe incluir los archivos correspondientes a cada una de las señales fisiológicas disponibles (ECG, EDA, EMG, PPG, RESP y SKT), así como los archivos de marcas temporales (**Triggers**) empleados durante el protocolo experimental.

Si se desea trabajar con el dispositivo **Empatica E4**, la carpeta **Empatica_data** debe contener los archivos correspondientes a las señales de acelerometría (**ACC**), volumen del pulso sanguíneo (**BVP**), actividad electrodérmica (**EDA**), frecuencia cardíaca (**HR**), temperatura (**TEMP**) y el resto de archivos generados por el dispositivo.

El archivo **SubjectX_Session_Times.csv** contiene las **marcas temporales del protocolo experimental**, es decir, los instantes de inicio y fin de cada fase de la sesión. Esta información permite a BioVisor delimitar las distintas fases del experimento y asignar correctamente las etiquetas empleadas durante el entrenamiento de los modelos.

Nota: es importante respetar tanto los nombres de las carpetas como su estructura interna. Cualquier modificación en la jerarquía de directorios puede impedir que la aplicación localice correctamente los sujetos y las señales durante el proceso de carga.

Una vez preparada la base de datos con esta estructura, BioVisor podrá localizar automáticamente los sujetos y las señales disponibles durante el proceso de carga.

2. Primeros pasos con BioVisor

En esta sección se explica el procedimiento necesario para ejecutar BioVisor por primera vez. Para ello es necesario disponer del repositorio del proyecto y de un entorno de Python con todas las dependencias instaladas.

2.1. Obtención del proyecto

El primer paso consiste en acceder al repositorio de **GitHub** donde se encuentra el código fuente de BioVisor (<https://github.com/raquelgomez2003/Trabajo-de-Fin-de-Grado/tree/main/BioVisor>). Una vez abierto el repositorio, este puede descargarse de dos formas diferentes: clonándolo mediante **Git** o descargándolo directamente como un archivo comprimido en formato ZIP.

Si se dispone de **Git** instalado, el repositorio puede clonarse ejecutando el siguiente comando desde una terminal:

```
git clone
<https://github.com/raquelgomez2003/Trabajo-de-Fin-de-Grado/tree/main/BioVisor>
```

En caso contrario, basta con seleccionar la opción **Code** y posteriormente **Download ZIP**. Una vez descargado, se debe descomprimir el contenido en la ubicación deseada del equipo.

Tras completar este proceso, se dispondrá de toda la estructura del proyecto, incluyendo el código fuente de la aplicación y los distintos módulos necesarios para su funcionamiento.




Figura 1: Descarga del proyecto desde el repositorio de GitHub.

2.2. Instalación de las dependencias

Antes de ejecutar la aplicación conviene instalar todas las librerías necesarias. Si el proyecto incluye un archivo `requirements.txt`, todas las dependencias pueden instalarse de una sola vez situándose en la carpeta del proyecto y ejecutando:

```
pip install -r requirements.txt
```

Se recomienda realizar la instalación dentro de un *entorno virtual*, con el fin de evitar conflictos con otras versiones de las librerías instaladas en el sistema. Un entorno virtual puede crearse y activarse de la siguiente manera:

```
python -m venv venv
venv\Scripts\activate      # En Windows
source venv/bin/activate   # En Linux o macOS
```

2.3. Ejecución de la aplicación

Una vez descargado el repositorio e instaladas las dependencias, se debe abrir el proyecto utilizando un entorno de desarrollo compatible con Python, como **Visual Studio Code** o **PyCharm**.

El punto de entrada de la aplicación es el archivo `main.py`, situado en el directorio principal del proyecto. Para iniciar BioVisor únicamente es necesario ejecutar dicho archivo.

La ejecución puede realizarse desde el propio entorno de desarrollo o mediante una terminal, situándose previamente en la carpeta del proyecto y ejecutando el siguiente comando:

```
python main.py
```

Nota: si la ruta del proyecto contiene **espacios** en los nombres de las carpetas, es recomendable indicar la ruta entre comillas al desplazarse hasta ella, con el fin de evitar errores al ejecutar los comandos desde la terminal.

Si todas las dependencias se encuentran correctamente instaladas, la aplicación se iniciará mostrando la ventana principal de BioVisor, desde la que será posible cargar una base de datos, seleccionar el dispositivo de adquisición, configurar los parámetros del análisis y visualizar las señales fisiológicas disponibles.

A partir de este momento, el usuario podrá comenzar a utilizar todas las funcionalidades descritas en los apartados siguientes de este manual.

3. Explicación de la interfaz

La *interfaz gráfica* de BioVisor se organiza en tres ventanas principales que siguen el flujo de trabajo de la aplicación: primero la **configuración de la sesión**, después el **visor y analizador de señales** y, dentro de este, el panel de **controles de análisis**. En los apartados siguientes se describe la función de cada elemento numerado.

3.1. Ventana de configuración de la sesión

Al iniciar BioVisor se muestra la ventana **Session Setup** (Figura 2), desde la que se configura la base de datos antes de cargar las señales.




Figura 2: Ventana de configuración de la sesión (Session Setup).

Cuadro 1: Elementos de la ventana de configuración de la sesión.

N.º	Descripción
1	Browse... — Abre el explorador de archivos para seleccionar la carpeta que contiene la base de datos (Dataset folder).
2	Device type — Selecciona el dispositivo de adquisición, Biopac o Empatica . Según la opción elegida, se muestran las señales compatibles con dicho sistema.
3	Number of subjects — Indica el número de sujetos que se cargarán desde la base de datos.
4	Signals to load · Sampling frequency (Hz) — Tabla donde se marca qué señales cargar (columna Include) y se define su <i>frecuencia de muestreo</i> en Hz (columna Fs). En el ejemplo, para Empatica: BVP a 64 Hz, EDA a 4 Hz, TEMP a 4 Hz, ACC a 32 Hz y HR a 1 Hz.
5	Confirm & Open Viewer — Confirma la configuración y abre la ventana principal del visor.

3.2. Ventana del visor y analizador de señales

Tras confirmar la configuración se abre la ventana principal **Biomedical Signal Viewer & Analyser** (Figura 3), donde se visualizan las señales y se ejecutan los análisis.




Figura 3: Ventana principal del visor y analizador de señales.

Cuadro 2: Elementos de la ventana del visor y analizador.

N.º	Descripción
1	New Session — Inicia una nueva sesión, regresando a la ventana de configuración.
2	Apply artifact filter — Activa o desactiva el <i>filtrado de artefactos</i> sobre las señales antes de su representación y análisis.
3	Subjects — Panel de navegación para seleccionar el sujeto que se desea visualizar o analizar.
4	Phase Intervals (seconds) — Define, en segundos, los intervalos de cada fase del protocolo: Calming (relajación) y Stress (estrés). Todo lo que quede fuera de ambos intervalos se considera fase de reposo (Relax).
5	Update Viewer / Run Analysis / Reset App — Actualiza la visualización con los parámetros actuales, ejecuta el análisis de aprendizaje automático y reinicia la aplicación, respectivamente.
6	Signal Viewer / Analysis — Pestañas para alternar entre el visor de señales y el módulo de análisis .
7	Selector de señal (ECG, EDA, EMG, PPG, RESP, SKT, Global) — Elige qué señal se representa. La opción Global muestra todas las señales superpuestas.
8	Controles de ventana — Minimizar, maximizar y cerrar la aplicación.
9	Barra de estado — Informa del progreso de la carga de datos y del estado del análisis.
10	Secciones desplegables por clasificador (LightGBM, etc.) — Despliegan u ocultan los resultados obtenidos con cada modelo.
11	Expand — Amplía la gráfica correspondiente para poder examinarla en detalle.

3.3. Panel de controles de análisis

Dentro de la pestaña **Analysis** se encuentra el panel de **Analysis controls** (Figura 4), desde el que se configura qué se analiza y qué resultados se generan antes de pulsar **Run Analysis**.




Figura 4: Panel de controles de análisis.

Cuadro 3: Elementos del panel de controles de análisis.

N.º	Descripción
1	Signals to analyse — Selecciona qué señales fisiológicas (ECG, EDA, EMG, PPG, RESP, SKT) se incluyen en el análisis.
2	Classifiers — Elige los <i>algoritmos de clasificación</i> que se entrenan y comparan: Random Forest , LightGBM , SVM y KNN .
3	Plot types — Selecciona las representaciones que se generan: diagramas de cajas (Boxplots), curva ROC, evolución temporal del estrés (Stress timeline), intervalos RR a partir del ECG y frecuencia respiratoria a partir de la RESP.
4	Window size (s) / Step size (s) — Definen el tamaño de la ventana temporal y el desplazamiento entre ventanas (en segundos) empleados en la extracción de características.

4. Guía de uso paso a paso

En esta sección se describe el **flujo de trabajo completo** de BioVisor, desde la carga de la base de datos hasta la interpretación de los resultados. Se recomienda seguir el orden indicado,

ya que la aplicación está diseñada para trabajar de forma secuencial: configuración, carga, visualización y análisis.

4.1. Selección de la base de datos

El primer paso consiste en indicar a BioVisor la ubicación de la base de datos que se desea analizar. Mediante el **selector de carpeta** (elemento 1 de la interfaz) se navega hasta el directorio principal que contiene las carpetas de los distintos sujetos, tal y como se describió en la Sección 1.3.

Una vez seleccionada la carpeta, la aplicación explora automáticamente su contenido y detecta los sujetos disponibles, dejando la base de datos preparada para la carga posterior.




Figura 5: Selección de la carpeta de la base de datos.

4.2. Selección del dispositivo de adquisición

A continuación se selecciona el **dispositivo de adquisición** (elemento 2) con el que se registraron las señales que se desean analizar: **Biopac** o **Empatica E4**. Esta elección es importante, ya que BioVisor adapta automáticamente el procesamiento a las características propias de cada dispositivo.

En el caso del **Biopac**, la aplicación trabaja con señales de alta frecuencia de muestreo, como el ECG, la EDA, el EMG, la PPG, la RESP y la SKT. En el caso de la **Empatica E4**, cada señal se registra con su *frecuencia de muestreo nativa* (por ejemplo, BVP a 64 Hz, EDA y TEMP a 4 Hz o ACC a 32 Hz), y BioVisor respeta dichas frecuencias durante todo el procesamiento en lugar de forzar un remuestreo común, con el fin de preservar la información original de cada señal.

4.3. Configuración de las señales

Mediante el panel de **configuración de señales** (elemento 3) el usuario indica qué señales fisiológicas desea cargar y analizar. De esta forma es posible centrar el análisis únicamente en las señales de interés, reduciendo el tiempo de carga y facilitando la visualización.

Las señales disponibles dependen del dispositivo seleccionado en el paso anterior, mostrándose únicamente aquellas compatibles con el sistema de adquisición elegido.

4.4. Parámetros de extracción de características

En el panel de **extracción de características** (elemento 4) se configuran los parámetros que determinan cómo se segmentan las señales para el posterior entrenamiento de los modelos. Los dos parámetros principales son:

- **Tamaño de la ventana temporal:** duración (en segundos) de cada segmento de señal sobre el que se calculan las características. Ventanas más largas capturan tendencias más lentas, mientras que ventanas más cortas ofrecen mayor resolución temporal.
- **Desplazamiento entre ventanas:** distancia (en segundos) entre el inicio de una ventana y el de la siguiente. Un desplazamiento menor que el tamaño de la ventana produce *solapamiento* entre segmentos, aumentando el número de muestras disponibles.

Sobre cada ventana temporal, BioVisor calcula un conjunto de **características** representativas de cada señal (estadísticos de tiempo, características de frecuencia cardíaca, medidas de variabilidad, etc.), que constituyen la entrada de los modelos de clasificación.

4.5. Preprocesado de las señales

El panel de **preprocesado** (elemento 5) permite aplicar un **filtrado automático** a las señales antes de su análisis, cuando esté disponible para el tipo de señal seleccionado. El objetivo de este paso es reducir el ruido y los artefactos presentes en los registros, mejorando así la calidad de las características extraídas y, en consecuencia, el rendimiento de los modelos.

4.6. Carga de la base de datos

Una vez configurados todos los parámetros anteriores, se pulsa el **botón de carga** (elemento 6) para que BioVisor procese la base de datos. Durante este proceso, la aplicación recorre cada sujeto, carga las señales seleccionadas, aplica el preprocesado configurado, delimita las fases del protocolo a partir de las marcas temporales y prepara todo para la visualización.

El progreso de la carga se muestra en la **barra de estado** (elemento 12), que informa en todo momento del estado del proceso. En bases de datos con muchos sujetos o señales de alta frecuencia de muestreo, este paso puede tardar algunos instantes.

5. Visualización de señales

Una vez cargada la base de datos, BioVisor muestra las señales fisiológicas en el **área principal de representación** (elemento 7). Esta sección describe con detalle las herramientas de visualización disponibles.

5.1. Representación de las señales originales

En el área principal se representan las **señales originales** de cada sujeto a lo largo del tiempo. Sobre la gráfica se destacan además las **regiones correspondientes a las distintas fases del protocolo experimental**, lo que permite relacionar de forma visual el comportamiento de las señales con cada momento del experimento (fases de reposo, de tarea o de estrés inducido, según el protocolo empleado).




Figura 6: Visualización de una señal fisiológica y las fases del protocolo.

5.2. Navegación entre sujetos y señales

Mediante el **panel de navegación** (elemento 8) el usuario puede desplazarse fácilmente entre los distintos **sujetos** de la base de datos y entre las diferentes **señales** disponibles para cada uno de ellos. De este modo es posible comparar el comportamiento de una misma señal en distintos sujetos o revisar todas las señales de un sujeto concreto de forma ordenada.

5.3. Características fisiológicas derivadas

Además de las señales originales, BioVisor permite visualizar **características fisiológicas derivadas**, que aportan información adicional sobre el estado del sujeto. Entre ellas se encuentran:

- **Intervalos RR:** tiempo entre latidos consecutivos, obtenido a partir de la detección de los picos R en el ECG o de la señal BVP.
- **Frecuencia cardíaca (HR):** número de latidos por minuto, derivada de los intervalos RR.
- **Frecuencia respiratoria:** obtenida a partir de la señal de respiración (RESP).
- **Probabilidad de estrés:** estimación temporal proporcionada por los modelos de clasificación, descrita en la Sección 7.



Figura 7: Representación de características fisiológicas derivadas.

6. Modelos de aprendizaje automático

BioVisor incorpora un conjunto de **algoritmos de clasificación** que permiten estimar de forma automática la presencia de estrés a partir de las características extraídas de las señales fisiológicas. Esta sección describe los modelos disponibles y el procedimiento de entrenamiento y evaluación.

6.1. Entrenamiento de los modelos

Las herramientas de **entrenamiento** (elemento 9) permiten ejecutar el proceso de aprendizaje a partir de las características extraídas durante la carga. El entrenamiento se realiza empleando las **etiquetas del protocolo experimental**, obtenidas a partir de las marcas temporales de cada sesión, que indican a qué fase (y, por tanto, a qué estado) corresponde cada ventana temporal.

Para obtener una evaluación honesta del rendimiento, BioVisor emplea **validación cruzada estratificada**, que mantiene la proporción de clases en cada partición y evita que los resultados se vean sesgados por un reparto desigual de las muestras.

6.2. Selección del algoritmo de clasificación

Mediante el **selector de algoritmo** (elemento 10) el usuario puede elegir entre los distintos modelos de clasificación implementados:

- **Random Forest:** conjunto de árboles de decisión que combina sus predicciones, robusto frente al sobreajuste y útil para estimar la importancia de las características.
- **LightGBM:** algoritmo de *gradient boosting* eficiente y de alto rendimiento, especialmente adecuado para grandes volúmenes de datos.
- **SVM** (*Support Vector Machine*): clasificador que busca el hiperplano de separación óptimo entre las clases.
- **KNN** (*K-Nearest Neighbors*): clasificador basado en la similitud con las muestras más cercanas del conjunto de entrenamiento.

La posibilidad de seleccionar distintos algoritmos permite **comparar su rendimiento** sobre las mismas señales y características, facilitando el estudio de qué enfoque resulta más adecuado para cada conjunto de datos.

7. Visualización de resultados

Una vez entrenado y evaluado el modelo seleccionado, BioVisor muestra los resultados en el **panel de resultados** (elemento 11). La aplicación proporciona distintas representaciones gráficas que permiten interpretar el rendimiento del clasificador de forma sencilla.

7.1. Curvas ROC

Las **curvas ROC** (*Receiver Operating Characteristic*) representan la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos para distintos umbrales de decisión. El área bajo la curva (AUC) resume el rendimiento global del modelo: cuanto más próxima a 1, mejor es la capacidad de discriminación entre las clases.




Figura 8: Curva ROC del modelo de clasificación.

7.2. Diagramas de cajas

Los **diagramas de cajas** (*boxplots*) permiten comparar la distribución de una métrica o de una característica entre las distintas clases o entre los distintos pliegues de la validación cruzada, mostrando la mediana, los cuartiles y los posibles valores atípicos.




Figura 9: Diagrama de cajas de los resultados.

7.3. Evolución temporal de la probabilidad de estrés

Por último, BioVisor representa la **evolución temporal de la probabilidad de estrés** a lo largo de la sesión. Esta gráfica muestra, para cada ventana temporal, la probabilidad estimada por el modelo de que el sujeto se encuentre en un estado de estrés, lo que permite relacionar dicha estimación con las distintas fases del protocolo experimental.

En este tipo de representaciones, los ejes de la probabilidad de estrés y de las señales o mapas de calor asociados se encuentran *alineados temporalmente*, de modo que resulta sencillo comparar visualmente ambos elementos y localizar los instantes en los que el modelo detecta un mayor nivel de estrés.




Figura 10: Evolución temporal de la probabilidad de estrés.

8. Resolución de problemas frecuentes

A continuación se recogen algunas de las incidencias más habituales que pueden surgir durante el uso de BioVisor, junto con las recomendaciones para resolverlas.

- **La aplicación no encuentra los sujetos o las señales.** Conviene revisar que la estructura de carpetas coincide exactamente con la descrita en la Sección 1.3, respetando los nombres de los directorios y de los archivos.
- **Errores al ejecutar comandos por rutas con espacios.** Si la ruta del proyecto o de la base de datos contiene espacios, se recomienda indicarla entre comillas al desplazarse hasta ella desde la terminal.
- **Diferencias de duración entre registros.** Es habitual que las sesiones registradas con **Empatica E4** tengan una duración mayor que las de **Biopac**, ya que el dispositivo

puede seguir registrando más allá de la ventana del protocolo. BioVisor emplea las marcas temporales de cada sesión para delimitar la parte correspondiente al experimento.

- **Faltan dependencias de Python.** Si al ejecutar `main.py` aparece un error indicando que falta alguna librería, conviene comprobar que todas las dependencias se han instalado correctamente, tal y como se describe en la Sección 2.
- **La carga es lenta.** En bases de datos con muchos sujetos o señales de alta frecuencia de muestreo, el proceso de carga puede tardar. Seleccionar únicamente las señales de interés en el panel de configuración ayuda a reducir el tiempo de procesamiento.

9. Conclusión

A lo largo de este manual se ha descrito el procedimiento necesario para instalar, configurar y utilizar la aplicación **BioVisor**, así como las principales funcionalidades que ofrece para el análisis de señales fisiológicas y la detección automática del estrés mediante técnicas de aprendizaje automático.

Se ha explicado cómo preparar correctamente la estructura de las bases de datos compatibles, cómo ejecutar la aplicación a partir del repositorio del proyecto y cómo utilizar cada uno de los elementos de la interfaz gráfica para cargar señales, configurar el análisis, entrenar los modelos disponibles y visualizar los resultados obtenidos. Asimismo, se han presentado las distintas herramientas de representación y análisis incorporadas en BioVisor, permitiendo al usuario interpretar de forma sencilla la información fisiológica registrada durante los experimentos.

Gracias a su interfaz intuitiva y a la automatización de las diferentes etapas del procesamiento, BioVisor constituye una herramienta que facilita el estudio de señales biomédicas tanto en el ámbito de la investigación como en entornos docentes. La posibilidad de trabajar con diferentes dispositivos de adquisición, como **Biopac** y **Empatica E4**, junto con la integración de varios algoritmos de aprendizaje automático, convierte a la aplicación en una plataforma flexible para la exploración y evaluación de distintos enfoques de detección del estrés.

Se recomienda consultar este manual siempre que surjan dudas sobre el funcionamiento de la aplicación o la configuración de alguno de sus parámetros. Del mismo modo, futuras versiones de BioVisor podrán incorporar nuevas funcionalidades, dispositivos compatibles y modelos de clasificación, ampliando así las capacidades descritas en este documento.